

Formation Chef de Projet IA

Fondamentaux du Machine Learning

Thomas Walter Chloé-Agathe Azencott Florian Massip

Center for Computational Biology (CBIO)
Mines Paris – Institut Curie – INSERM U900
PSL Research University & PR[AI]RIE, Paris, France

November 2022

Programme

- Introduction à l'apprentissage automatique
- **Cours 1** : Minimisation du risque empirique
- **Cours 2** : Régularisation et sélection de modèle
- **Cours 3** : Arbres et méthodes ensemblistes
- **Cours 4** : Méthodes à noyaux
- **Cours 5** : Réduction de dimension
- **Cours 6** : Clustering
- Travaux pratiques : mise en œuvre des notions et algorithmes avec scikit-learn (Python numérique).

Cours 6 – Clustering

Clustering ou partitionnement


- **Clustering** : partitionner les données en sous-ensembles (**clusters**) homogènes
- Exemples :
 - **segmentation de marché**
 - **communautés** sur un réseau social
 - **topic modeling** (thématique de textes)
 - **compression** ou **segmentation d'images**
 - **sous-types** d'une maladie

Clustering : Motivation

- Étude de données **non-étiquetées**
- Analyse **exploratoire**
- **Visualisation**
- Peut précéder une phase d'**inférence** (ex. topic modeling)

1. Évaluation d'un clustering

1.1 Critères géométriques



- **Homogénéité** (tightness)

- Pour le cluster k :

$$T_k = \frac{1}{|\mathcal{C}_k|} \sum_{\vec{x} \in \mathcal{C}_k} d(\vec{x}, \vec{\mu}_k)$$


- **Centroïde** du cluster $\mathcal{C}$:

$$\vec{\mu}_{\mathcal{C}} = \frac{1}{|\mathcal{C}|} \sum_{\vec{x} \in \mathcal{C}} \vec{x}$$

- **Médoïde** : l'élément de $\mathcal{C}$ le plus proche de $\vec{\mu}_{\mathcal{C}}$

- Pour le clustering complet : $T = \frac{1}{K} \sum_{k=1}^K T_k$

1.1 Critères géométriques



- **Séparabilité**

- Pour les clusters k et l :

$$s_{kl} = d(\vec{\mu}_k, \vec{\mu}_l)$$

- Pour le clustering :

$$S = \frac{2}{K(K-1)} \sum_{k=1}^{K-1} \sum_{l=k+1}^K s_{kl}$$

1.1 Critères géométriques

- **Coefficient de silhouette**

- Pour un point $\vec{x}$:

$$a(\vec{x}) = \frac{1}{|\mathcal{C}_{k(\vec{x})}| - 1} \sum_{\vec{u} \in \mathcal{C}_{k(\vec{x})}} d(\vec{x}, \vec{u})$$

$$b(\vec{x}) = \min_{l \neq k(\vec{x})} \frac{1}{|\mathcal{C}_l|} \sum_{u \in \mathcal{C}_l} d(\vec{u}, \vec{x})$$

$$s(\vec{x}) = \frac{b(\vec{x}) - a(\vec{x})}{\max(a(\vec{x}), b(\vec{x}))}$$

- Pour le clustering :

$$s = \frac{1}{n} \sum_{i=1}^n s(\vec{x}^i).$$

1.2 Stabilité des clusters




1.3 Comparaison à des étiquettes connues

- Difficulté : les clusters sont numérotés arbitrairement
- **Indice de Rand**

$$RI = \frac{2}{n(n-1)} \sum_{i=1}^n \sum_{l=i+1}^n \mathbb{1}_{k(\vec{x}^i)=k(\vec{x}^l)} \mathbb{1}_{y^i=y^l} + \mathbb{1}_{k(\vec{x}^i) \neq k(\vec{x}^l)} \mathbb{1}_{y^i \neq y^l}.$$

2. Clustering hiérarchique

Dendrogramme



Construction

- Construction **agglomérative** (bottom-up)
 - Initialement : chaque point est son propre cluster
 - On fusionne itérativement les clusters les plus proches
- Construction **divisive** (top-down)
 - Initialement : tous les points sont dans le même cluster
 - On sépare itérativement les clusters en deux

Fonctions de lien

- **Fonction de lien** (linkage) : distance entre deux clusters
- **Lien simple** (single linkage)

$$d_{\text{simple}}(\mathcal{C}_k, \mathcal{C}_l) = \min_{(\vec{u}, \vec{v}) \in \mathcal{C}_k \times \mathcal{C}_l} d(\vec{u}, \vec{v}).$$

Fonctions de lien

- **Fonction de lien** (linkage) : distance entre deux clusters
- **Lien simple** (single linkage)

$$d_{\text{simple}}(\mathcal{C}_k, \mathcal{C}_l) = \min_{(\vec{u}, \vec{v}) \in \mathcal{C}_k \times \mathcal{C}_l} d(\vec{u}, \vec{v}).$$

- **Lien complet** (complete linkage)

$$d_{\text{complet}}(\mathcal{C}_k, \mathcal{C}_l) = \max_{(\vec{u}, \vec{v}) \in \mathcal{C}_k \times \mathcal{C}_l} d(\vec{u}, \vec{v}).$$

Fonctions de lien

- **Fonction de lien** (linkage) : distance entre deux clusters

- **Lien simple** (single linkage)

$$d_{\text{simple}}(\mathcal{C}_k, \mathcal{C}_l) = \min_{(\vec{u}, \vec{v}) \in \mathcal{C}_k \times \mathcal{C}_l} d(\vec{u}, \vec{v}).$$

- **Lien complet** (complete linkage)

$$d_{\text{complet}}(\mathcal{C}_k, \mathcal{C}_l) = \max_{(\vec{u}, \vec{v}) \in \mathcal{C}_k \times \mathcal{C}_l} d(\vec{u}, \vec{v}).$$

- **Lien moyen** (average linkage) ou UPGMA (Unweighted Paired Group Method with Arithmetic mean)

$$d_{\text{moyen}}(\mathcal{C}_k, \mathcal{C}_l) = \frac{1}{|\mathcal{C}_k|} \frac{1}{|\mathcal{C}_l|} \sum_{\vec{u} \in \mathcal{C}_k} \sum_{\vec{v} \in \mathcal{C}_l} d(\vec{u}, \vec{v}).$$

Fonctions de lien

- **Fonction de lien** (linkage) : distance entre deux clusters
- **Lien centroïdal** (centroid linkage)

$$d_{\text{centroidal}}(\mathcal{C}_k, \mathcal{C}_l) = d\left(\frac{1}{|\mathcal{C}_k|} \sum_{\vec{u} \in \mathcal{C}_k} \vec{u}, \frac{1}{|\mathcal{C}_l|} \sum_{\vec{v} \in \mathcal{C}_l} \vec{v}\right) = d(\vec{\mu}_k, \vec{\mu}_l).$$

3. Algorithme des k-moyennes

Variance intra-cluster

- **Variance intra-cluster**

$$\text{Var}_{\text{in}}(\mathcal{C}) = \frac{1}{|\mathcal{C}|} \sum_{\vec{x} \in \mathcal{C}} \|\vec{x} - \vec{\mu}\|_2^2.$$

- Minimiser la variance intra-cluster : créer des clusters **homogènes**

Algorithme de Lloyd

- **Initialisation** : choisir les $\vec{\mu}_1, \vec{\mu}_2, \dots, \vec{\mu}_K$ parmi les données.
- **Affecter** chaque observation $\vec{x} \in \mathcal{D}$ au centroïde dont elle est le plus proche :

$$k(\vec{x}^i) = \arg \min_{k=1, \dots, K} \|\vec{x}^i - \vec{\mu}_k\|_2^2$$

- **Recalculer** les centroïdes $\vec{\mu}_k$.
- **Répéter** jusqu'à ce que les affectations ne changent plus.

Algorithme de Lloyd

- **Avantages :**
 - Converge rapidement en pratique

Algorithme de Lloyd

- **Avantages :**

- Converge rapidement en pratique

- **Inconvénients :**

- Nécessité de fixer K
- Approche **gloutonne** : pas de garantie de minimum global
- **Stochasticité** : dépend de l'initialisation

Algorithme de Lloyd

- **Avantages :**

- Converge rapidement en pratique

- **Inconvénients :**

- Nécessité de fixer K
- Approche **gloutonne** : pas de garantie de minimum global
- **Stochasticité** : dépend de l'initialisation → k-means++
- Clusters nécessairement **convexes**

Algorithme de Lloyd

- **Avantages :**


- Converge rapidement en pratique

- **Inconvénients :**

- Nécessité de fixer K
- Approche **gloutonne** : pas de garantie de minimum global
- **Stochasticité** : dépend de l'initialisation → k-means++
- Clusters nécessairement **convexes** → kernel k-means

4. DBSCAN


DBSCAN: Motivation



- Idée : utiliser la **densité**

DBSCAN

- Idée : itérer **de proche en proche** par des **voisinages** (boules) de rayon ϵ
- Les points **isolés** (min $n_{\min}$ points par cluster) sont du bruit



DBSCAN : avantages et inconvénients

- **Avantages :**
 - n'impose pas de forme particulière
 - simple, pas de définition du nombre de clusters
 - robustesse aux données aberrantes

DBSCAN : avantages et inconvénients

- **Avantages :**

- n'impose pas de forme particulière
- simple, pas de définition du nombre de clusters
- robustesse aux données aberrantes

- **Inconvénients :**

- ne sait pas gérer des écarts
- peu de résultats théoriques
- pas applicable en très haute dimension

Recap
