

Formation Chef de Projet IA

Fondamentaux du Machine Learning

Thomas Walter Chloé-Agathe Azencott Florian Massip

Center for Computational Biology (CBIO)
Mines Paris – Institut Curie – INSERM U900
PSL Research University & PR[AI]RIE, Paris, France

November 26, 2025

Programme

- Introduction à l'apprentissage automatique
- **Cours 1** : Minimisation du risque empirique
- **Cours 2** : Régularisation et sélection de modèle
- **Cours 3** : Arbres et méthodes ensemblistes
- **Cours 4** : Méthodes à noyaux
- **Cours 5** : Réduction de dimension
- **Cours 6** : Clustering
- Travaux pratiques : mise en œuvre des notions et algorithmes avec scikit-learn (Python numérique).

Minimisation du risque empirique

- Principe sur lequel de nombreux algorithmes **d'apprentissage supervisé** sont fondés.
- Ingrédients :
 - **Espace des hypothèses** (hypothesis space)
Quels modèles peut-on apprendre ?
 - **Fonction de perte / coût / erreur** (loss / cost / error function)
Comment quantifier l'erreur d'un modèle ?
 - Algorithme d'**optimisation**
Comment trouver un modèle qui fasse peu d'erreurs ?

1. Minimisation du risque empirique

1.1 Espace des hypothèses

- **Données :** $\mathcal{D} = \{(\vec{x}_1, y_1), (\vec{x}_2, y_2), \dots, (\vec{x}_n, y_n)\}$
 - n observations en p dimensions : $\vec{x}_i \in \mathbb{R}^p$
 - n étiquettes (labels) : $y_i \in \mathcal{Y}$

1.1 Espace des hypothèses

- **Données** : $\mathcal{D} = \{(\vec{x}_1, y_1), (\vec{x}_2, y_2), \dots, (\vec{x}_n, y_n)\}$
 - n observations en p dimensions : $\vec{x}_i \in \mathbb{R}^p$
 - n étiquettes (labels) : $y_i \in \mathcal{Y}$
- **Espace des hypothèses** : l'ensemble $\mathcal{F}$ des **modèles** que l'algorithme d'apprentissage va considérer.

1.1 Espace des hypothèses

- **Données** : $\mathcal{D} = \{(\vec{x}_1, y_1), (\vec{x}_2, y_2), \dots, (\vec{x}_n, y_n)\}$
 - n observations en p dimensions : $\vec{x}_i \in \mathbb{R}^p$
 - n étiquettes (labels) : $y_i \in \mathcal{Y}$
- **Espace des hypothèses** : l'ensemble $\mathcal{F}$ des **modèles** que l'algorithme d'apprentissage va considérer.
- **Modèles paramétriques** : on considère un ensemble paramétré de fonctions.

Exemple : $\mathcal{F} = \{\vec{x} \mapsto \alpha_1 x_1^{\beta_1} + \alpha_2 x_2^{\beta_2} + \dots + \alpha_p x_p^{\beta_p}\}$

Le but de l'apprentissage est de déterminer $\alpha_1, \dots, \alpha_p, \beta_1, \dots, \beta_p$.

1.2 Fonction de perte

- **Quantifier** l'erreur d'un modèle pour une observation.
- **Fonction de perte** : une fonction $L : \mathcal{Y} \times \mathcal{Y} \mapsto \mathbb{R}$

$L(y, f(\vec{x}))$ est d'autant plus grande que l'erreur consistant à prédire $f(\vec{x})$ au lieu de y est grande.

1.2 Fonction de perte

- **Quantifier** l'erreur d'un modèle pour une observation.
- **Fonction de perte** : une fonction $L : \mathcal{Y} \times \mathcal{Y} \mapsto \mathbb{R}$

$L(y, f(\vec{x}))$ est d'autant plus grande que l'erreur consistant à prédire $f(\vec{x})$ au lieu de y est grande.

- **Perte 0/1** (0/1 loss) pour la classification :

$$L : \quad \{0, 1\} \times \{0, 1\} \rightarrow \mathbb{R}$$
$$(y, f(\vec{x})) \mapsto \begin{cases} 0 & \text{si } f(\vec{x}) = y \\ 1 & \text{sinon.} \end{cases}$$

1.2 Fonction de perte

- **Quantifier** l'erreur d'un modèle pour une observation.

- **Fonction de perte** : une fonction $L : \mathcal{Y} \times \mathcal{Y} \mapsto \mathbb{R}$

$L(y, f(\vec{x}))$ est d'autant plus grande que l'erreur consistant à prédire $f(\vec{x})$ au lieu de y est grande.

- **Perte 0/1** (0/1 loss) pour la classification :

$$L : \quad \{0, 1\} \times \{0, 1\} \rightarrow \mathbb{R}$$
$$(y, f(\vec{x})) \mapsto \begin{cases} 0 & \text{si } f(\vec{x}) = y \\ 1 & \text{sinon.} \end{cases}$$

- **Perte quadratique** (quadratic loss) pour la régression :

$$L : \quad \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}$$
$$(y, f(\vec{x})) \mapsto (y - f(\vec{x}))^2$$

1.3 Risque empirique

- **Risque :**
- Erreur attendue du modèle sur toutes données possibles

Formellement : l'espérance de la fonction de perte

$$\mathcal{R}(f) = \mathbb{E}[L(Y, f(X))]$$

- $(\vec{x}_1, y_1), (\vec{x}_2, y_2), \dots, (\vec{x}_n, y_n)$ échantillon de (X, Y)
- X vecteur aléatoire réel de dimension p ; Y variable aléatoire dans $\mathcal{Y}$

- **Risque empirique :** moyenne de la fonction de perte sur les données

$$\mathcal{R}_{\text{emp}}(f) = \frac{1}{n} \sum_{i=1}^n L(y_i, f(\vec{x}_i))$$

1.4 Minimisation du risque empirique

- Apprendre un modèle = trouver un modèle de l'espace des hypothèses qui minimise le risque empirique


$$\hat{f} = \arg \min_{f \in \mathcal{F}} \frac{1}{n} \sum_{i=1}^n L(y_i, f(\vec{x}_i))$$

- C'est donc un problème d'optimisation
- Selon l'espace des hypothèses, la fonction de perte, et la procédure d'optimisation choisie :
 - La solution peut être unique (mais pas nécessairement)
 - La solution peut être explicite (rarement)
 - La solution peut être atteinte avec la précision souhaitée (parfois)
 - La solution ne peut être déterminée que par des heuristiques

2. Modèles linéaires


2.1 Régression linéaire univariée

- **Données :** $\mathcal{D} = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$
 - n observations dans $\mathbb{R} : x_i \in \mathbb{R} (p = 1)$
 - n étiquettes : $y_i \in \mathbb{R}$



2.1 Régression linéaire univariée

- **Données** : $\mathcal{D} = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$
 - n observations dans $\mathbb{R} : x_i \in \mathbb{R} (p = 1)$
 - n étiquettes : $y_i \in \mathbb{R}$



- **Espace des hypothèses** : $\mathcal{F} = \{x \mapsto ax + b; (a, b) \in \mathbb{R}^2\}$

2.1 Régression linéaire univariée

- **Espace des hypothèses** : $\mathcal{F} = \{x \mapsto ax + b; (a, b) \in \mathbb{R}^2\}$

2.1 Régression linéaire univariée

- **Espace des hypothèses** : $\mathcal{F} = \{x \mapsto ax + b; (a, b) \in \mathbb{R}^2\}$
- **Fonction de perte** : perte quadratique $L(y, f(x)) = (y - f(x))^2$

2.1 Régression linéaire univariée

- **Espace des hypothèses** : $\mathcal{F} = \{x \mapsto ax + b; (a, b) \in \mathbb{R}^2\}$
- **Fonction de perte** : perte quadratique $L(y, f(x)) = (y - f(x))^2$
- **Minimisation du risque empirique** :

$$(\hat{a}, \hat{b}) = \arg \min_{(a,b) \in \mathbb{R}^2} \frac{1}{n} \sum_{i=1}^n (y_i - (ax_i + b))^2$$

2.1 Régression linéaire univariée

- **Espace des hypothèses** : $\mathcal{F} = \{x \mapsto ax + b; (a, b) \in \mathbb{R}^2\}$
- **Fonction de perte** : perte quadratique $L(y, f(x)) = (y - f(x))^2$
- **Minimisation du risque empirique** :

$$(\hat{a}, \hat{b}) = \arg \min_{(a,b) \in \mathbb{R}^2} \frac{1}{n} \sum_{i=1}^n (y_i - (ax_i + b))^2$$

Méthode des moindres carrés (ordinary least squares) connue depuis Legendre et Gauss.

Solution

- **Par annulation des dérivées partielles** : système de deux équations à deux inconnues

Solution explicite :

- Si $\sum_{i=1}^n x_i^2 \neq (\sum_{i=1}^n x_i)^2$, une **unique solution**

$$a = \frac{\sum_{i=1}^n x_i y_i - \frac{1}{n} \sum_{i=1}^n x_i \sum_{i=1}^n y_i}{\sum_{i=1}^n x_i^2 - \frac{1}{n} (\sum_{i=1}^n x_i)^2} \quad b = \frac{1}{n} \sum_{i=1}^n y_i - \frac{a}{n} \sum_{i=1}^n x_i$$

Solution

- **Par annulation des dérivées partielles** : système de deux équations à deux inconnues

Solution explicite :

- Si $\sum_{i=1}^n x_i^2 \neq (\sum_{i=1}^n x_i)^2$, une **unique solution**

$$a = \frac{\sum_{i=1}^n x_i y_i - \frac{1}{n} \sum_{i=1}^n x_i \sum_{i=1}^n y_i}{\sum_{i=1}^n x_i^2 - \frac{1}{n} (\sum_{i=1}^n x_i)^2} \quad b = \frac{1}{n} \sum_{i=1}^n y_i - \frac{a}{n} \sum_{i=1}^n x_i$$

- Sinon, le système est **indéterminé** et on a une infinité de solutions.

Solution

- **Par annulation des dérivées partielles** : système de deux équations à deux inconnues

Solution explicite :

- Si $\sum_{i=1}^n x_i^2 \neq (\sum_{i=1}^n x_i)^2$, une **unique solution**

$$a = \frac{\sum_{i=1}^n x_i y_i - \frac{1}{n} \sum_{i=1}^n x_i \sum_{i=1}^n y_i}{\sum_{i=1}^n x_i^2 - \frac{1}{n} (\sum_{i=1}^n x_i)^2} \quad b = \frac{1}{n} \sum_{i=1}^n y_i - \frac{a}{n} \sum_{i=1}^n x_i$$

- Sinon, le système est **indéterminé** et on a une infinité de solutions.
- **Par algorithme du gradient**

2.2 Régression linéaire multivariée

- Autre nom : **régression linéaire multiple**
- **Données** : $\mathcal{D} = \{(\vec{x}_1, y_1), (\vec{x}_2, y_2), \dots, (\vec{x}_n, y_n)\}$
 - n observations dans $\mathbb{R}^p$
 - n étiquettes : $y_i \in \mathbb{R}$
- **Espace des hypothèses** :

$$\mathcal{F} = \left\{ \vec{x} \mapsto \beta_0 + \sum_{j=1}^p \beta_j x_j ; \vec{\beta} \in \mathbb{R}^{p+1} \right\}$$

2.2 Régression linéaire multivariée

- Autre nom : **régression linéaire multiple**
- **Données** : $\mathcal{D} = \{(\vec{x}_1, y_1), (\vec{x}_2, y_2), \dots, (\vec{x}_n, y_n)\}$
 - n observations dans $\mathbb{R}^p$
 - n étiquettes : $y_i \in \mathbb{R}$
- **Espace des hypothèses** :

$$\mathcal{F} = \left\{ \vec{x} \mapsto \beta_0 + \sum_{j=1}^p \beta_j x_j ; \vec{\beta} \in \mathbb{R}^{p+1} \right\}$$

- **Fonction de perte** : perte quadratique $L(y, f(\vec{x})) = (y - f(\vec{x}))^2$

2.2 Régression linéaire multivariée

- Autre nom : **régression linéaire multiple**
- **Données** : $\mathcal{D} = \{(\vec{x}_1, y_1), (\vec{x}_2, y_2), \dots, (\vec{x}_n, y_n)\}$
 - n observations dans $\mathbb{R}^p$
 - n étiquettes : $y_i \in \mathbb{R}$
- **Espace des hypothèses** :

$$\mathcal{F} = \left\{ \vec{x} \mapsto \beta_0 + \sum_{j=1}^p \beta_j x_j ; \vec{\beta} \in \mathbb{R}^{p+1} \right\}$$

- **Fonction de perte** : perte quadratique $L(y, f(\vec{x})) = (y - f(\vec{x}))^2$
- **Minimisation du risque empirique** :

$$\hat{\vec{\beta}} = \arg \min_{\vec{\beta} \in \mathbb{R}^{p+1}} \frac{1}{n} \sum_{i=1}^n \left(y_i - \left(\beta_0 + \sum_{j=1}^p \beta_j x_j \right) \right)^2$$

Écriture matricielle

$$\hat{\vec{\beta}} = \arg \min_{\vec{\beta} \in \mathbb{R}^{p+1}} \frac{1}{n} \sum_{i=1}^n \left(y_i - \left(\beta_0 + \sum_{j=1}^p \beta_j x_j \right) \right)^2$$

- La transformation $\vec{x} \leftarrow (1, x_1, \dots, x_p)$ permet d'écrire $f(\vec{x}) = \langle \vec{\beta}, \vec{x} \rangle$
- En notant $X \in \mathbb{R}^{n \times (p+1)}$ la matrice de données : $X_{i.} = \vec{x}_i$ et $\vec{y} \in \mathbb{R}^n$ le vecteur des étiquettes,

$$\sum_{i=1}^n \left(y_i - \left(\beta_0 + \sum_{j=1}^p \beta_j x_j \right) \right)^2 = (\vec{y} - X\vec{\beta})^\top (\vec{y} - X\vec{\beta})$$

- Le problème devient

$$\arg \min_{\vec{\beta} \in \mathbb{R}^{p+1}} \frac{1}{n} (\vec{y} - X\vec{\beta})^\top (\vec{y} - X\vec{\beta})$$

Solution

Minimiser $J : \mathbb{R}^{p+1} \rightarrow \mathbb{R}$

$$\vec{\beta} \mapsto \left(\vec{y} - X\vec{\beta} \right)^\top \left(\vec{y} - X\vec{\beta} \right)$$

- Problème **d'optimisation convexe**

Solution

Minimiser $J : \mathbb{R}^{p+1} \rightarrow \mathbb{R}$

$$\vec{\beta} \mapsto \left(\vec{y} - X\vec{\beta} \right)^\top \left(\vec{y} - X\vec{\beta} \right)$$

- Problème **d'optimisation convexe**
- **Gradient** de $J : \nabla J(\vec{\beta}) = -2X^\top(\vec{y} - X\vec{\beta})$
- En **annulant** ce gradient, on obtient

$$X^\top X\vec{\beta} = X^\top \vec{y}$$

Solution

Minimiser $J : \mathbb{R}^{p+1} \rightarrow \mathbb{R}$

$$\vec{\beta} \mapsto \left(\vec{y} - X\vec{\beta} \right)^\top \left(\vec{y} - X\vec{\beta} \right)$$

- Problème **d'optimisation convexe**
- **Gradient** de $J : \nabla J(\vec{\beta}) = -2X^\top (\vec{y} - X\vec{\beta})$
- En **annulant** ce gradient, on obtient

$$X^\top X \vec{\beta} = X^\top \vec{y}$$

- Solution :
 - Si $X^\top X$ **inversible**, alors $\vec{\beta}^* = (X^\top X)^{-1} X^\top \vec{y}$
 - Sinon, le système est indéterminé et on a une infinité de solutions.

Inversibilité de $X^\top X$

- $X^\top X$ est inversible ssi X est de rang colonne plein.

Inversibilité de $X^\top X$

- $X^\top X$ est inversible ssi X est de rang colonne plein.
- Ce n'est pas le cas si $p + 1 > n$
i.e. s'il y a **plus de variables que d'observations**
- Ce n'est pas le cas si des colonnes sont colinéaires
i.e. si des **variables sont fortement corrélées**

Inversibilité de $X^\top X$

- $X^\top X$ est inversible ssi X est de rang colonne plein.
- Ce n'est pas le cas si $p + 1 > n$
i.e. s'il y a **plus de variables que d'observations**
- Ce n'est pas le cas si des colonnes sont colinéaires
i.e. si des **variables sont fortement corrélées**
- L'inversion d'une matrice carrée de taille p est une opération en $\mathcal{O}(p^3)$

On utilise généralement **l'algorithme du gradient** même si $X^\top X$ est inversible.

2.3 Régression logistique

- **Données** : $\mathcal{D} = \{(\vec{x}_1, y_1), (\vec{x}_2, y_2), \dots, (\vec{x}_n, y_n)\}$
 - n observations dans $\mathbb{R}^p$
 - n étiquettes : $y_i \in \{0, 1\}$: **classification binaire**

2.3 Régression logistique


- **Données** : $\mathcal{D} = \{(\vec{x}_1, y_1), (\vec{x}_2, y_2), \dots, (\vec{x}_n, y_n)\}$
 - n observations dans $\mathbb{R}^p$
 - n étiquettes : $y_i \in \{0, 1\}$: **classification binaire**
- **Espace des hypothèses** : Considérer des fonctions linéaires n'a pas de sens pour prédire une valeur binaire.

2.3 Régression logistique

- **Données** : $\mathcal{D} = \{(\vec{x}_1, y_1), (\vec{x}_2, y_2), \dots, (\vec{x}_n, y_n)\}$
 - n observations dans $\mathbb{R}^p$
 - n étiquettes : $y_i \in \{0, 1\}$: **classification binaire**
- **Espace des hypothèses** : Considérer des fonctions linéaires n'a pas de sens pour prédire une valeur binaire.
 - f va modéliser **la probabilité d'appartenir à la classe positive**

2.3 Régression logistique

- **Données** : $\mathcal{D} = \{(\vec{x}_1, y_1), (\vec{x}_2, y_2), \dots, (\vec{x}_n, y_n)\}$
 - n observations dans $\mathbb{R}^p$
 - n étiquettes : $y_i \in \{0, 1\}$: **classification binaire**
- **Espace des hypothèses** : Considérer des fonctions linéaires n'a pas de sens pour prédire une valeur binaire.
 - f va modéliser **la probabilité d'appartenir à la classe positive**
 - la **fonction logistique** σ transforme un réel en une "probabilité"





- $\mathcal{F} = \left\{ \vec{x} \mapsto \sigma \left(\beta_0 + \langle \vec{\beta}, \vec{x} \rangle \right) ; \vec{\beta} \in \mathbb{R}^{p+1} \right\}$

2.3 Régression logistique

- Fonction de perte : **entropie croisée** (cross-entropy)

$$L : \{0, 1\} \times]0, 1[\rightarrow \mathbb{R}$$

$$(y, f(\vec{x})) \mapsto -y \log f(\vec{x}) - (1 - y) \log(1 - f(\vec{x}))$$



2.3 Régression logistique

- Fonction de perte : **entropie croisée** (cross-entropy)

$$L : \{0, 1\} \times]0, 1[\rightarrow \mathbb{R}$$
$$(y, f(\vec{x})) \mapsto -y \log f(\vec{x}) - (1 - y) \log(1 - f(\vec{x}))$$

Si $y = 1$, alors $L = -\log f(\vec{x})$. La perte va donc être minimisée si $f(\vec{x}) \rightarrow 1$.

Si $y = 0$, alors $L = -\log(1 - f(\vec{x}))$. La perte va donc être minimisée si $f(\vec{x}) \rightarrow 0$.

2.3 Régression logistique

- **Espace des hypothèses :** $\mathcal{F} = \{\vec{x} \mapsto \sigma(\beta_0 + \langle \vec{\beta}, \vec{x} \rangle) ; \vec{\beta} \in \mathbb{R}^{p+1}\}$
- **Fonction de perte :**
 $L : (y, f(\vec{x})) \mapsto -y \log f(\vec{x}) - (1 - y) \log(1 - f(\vec{x}))$
- **Minimisation du risque empirique :**

$$\arg \min_{\vec{\beta} \in \mathbb{R}^{p+1}} \frac{1}{n} \sum_{i=1}^n -y_i \log \sigma(\beta_0 + \langle \vec{\beta}, \vec{x}_i \rangle) - (1 - y_i) \log(1 - \sigma(\beta_0 + \langle \vec{\beta}, \vec{x}_i \rangle))$$

2.3 Régression logistique - Solution

- **Minimiser**

$$J : \vec{\beta} \mapsto \sum_{i=1}^n -y_i \log \sigma \left(\beta_0 + \langle \vec{\beta}, \vec{x}_i \rangle \right) - (1-y_i) \log \left(1 - \sigma \left(\beta_0 + \langle \vec{\beta}, \vec{x}_i \rangle \right) \right)$$

2.3 Régression logistique - Solution

- Minimiser

$$J : \vec{\beta} \mapsto \sum_{i=1}^n -y_i \log \sigma \left(\beta_0 + \langle \vec{\beta}, \vec{x}_i \rangle \right) - (1-y_i) \log \left(1 - \sigma \left(\beta_0 + \langle \vec{\beta}, \vec{x}_i \rangle \right) \right)$$

- J est une fonction **convexe** de $\vec{\beta}$

2.3 Régression logistique - Solution

- **Minimiser**

$$J : \vec{\beta} \mapsto \sum_{i=1}^n -y_i \log \sigma \left(\beta_0 + \langle \vec{\beta}, \vec{x}_i \rangle \right) - (1-y_i) \log \left(1 - \sigma \left(\beta_0 + \langle \vec{\beta}, \vec{x}_i \rangle \right) \right)$$

- J est une fonction **convexe** de $\vec{\beta}$
- En utilisant $\sigma'(u) = \sigma(u)(1 - \sigma(u))$,

$$\nabla J(\vec{\beta}) = \sum_{i=1}^n \left(y_i - \frac{1}{1 + \exp - \left(\beta_0 + \langle \vec{\beta}, \vec{x}_i \rangle \right)} \right)$$

⇒ Pas de solution explicite.

2.3 Régression logistique - Solution

- **Minimiser**

$$J : \vec{\beta} \mapsto \sum_{i=1}^n -y_i \log \sigma \left(\beta_0 + \langle \vec{\beta}, \vec{x}_i \rangle \right) - (1-y_i) \log \left(1 - \sigma \left(\beta_0 + \langle \vec{\beta}, \vec{x}_i \rangle \right) \right)$$

- J est une fonction **convexe** de $\vec{\beta}$
- En utilisant $\sigma'(u) = \sigma(u)(1 - \sigma(u))$,

$$\nabla J(\vec{\beta}) = \sum_{i=1}^n \left(y_i - \frac{1}{1 + \exp - \left(\beta_0 + \langle \vec{\beta}, \vec{x}_i \rangle \right)} \right)$$

⇒ Pas de solution explicite.

- On utilise donc systématiquement **l'algorithme du gradient**.

2.3 Régression logistique - Interprétation

- Le **coefficient de régression** β_j peut être interprété comme la contribution de la variable correspondante (x_j) au modèle
- À condition que les variables soient **centrées-réduites** pour être à la même échelle :

$$x_j \leftarrow \frac{x_j - \overline{x_j}}{\sigma_j}$$

- $\overline{x_j}$: moyenne de x_j sur les données
- σ_j : écart-type de x_j sur les données
- Attention à calculer $\overline{x_j}$ et σ_j sur le jeu d'entraînement uniquement, pour ne pas toucher au jeu de test.

2.3 Régression logistique - Entropie croisée et maximisation de vraisemblance

- On écrit $P(y_i | \vec{x}_i; \theta)$ la probabilité de prédire la classe y_i (donc de prédire la classe correcte).
- Probabilité que toutes les prédictions sont bonnes est la probabilité jointe de N bonnes prédictions :

$$\prod_{i=1}^N P(y_i | \vec{x}_i; \theta)$$

2.3 Régression logistique - Entropie croisée et maximisation de vraisemblance

- Approche de maximisation de la vraisemblance :

$$\begin{aligned}\theta^* &= \arg \max_{\theta} \prod_{i=1}^N P(y_i | \vec{x}_i; \theta) \\ &= \arg \max_{\theta} \sum_{i=1}^N \log P(y_i | \vec{x}_i; \theta) \\ &= \arg \min_{\theta} - \sum_{i=1}^N \log P(y_i | \vec{x}_i; \theta)\end{aligned}$$

2.3 Régression logistique - Entropie croisée et maximisation de vraisemblance

- Si on suppose qu'on prédit la probabilité a posteriori, on peut écrire :

$$\log P(y_i | (\vec{x}_i; \theta)) = y_i \log(f(\vec{x}_i; \theta)) + (1 - y_i) \log(1 - f(\vec{x}_i; \theta))$$

et on obtient :

$$\theta^* = \arg \min_{\theta} - \sum_{i=1}^N [y_i \log(f(\vec{x}_i; \theta)) + (1 - y_i) \log(1 - f(\vec{x}_i; \theta))]$$

- Nous voyons que minimiser l'entropie croisée est équivalent à maximiser la vraisemblance.

2.4 Analyse discriminante linéaire - règle Bayesienne 1/4

- Soient X et Y deux variables aléatoires, $P(X)$ et $P(Y)$ leurs probabilités marginales, $P(X, Y)$ la probabilité jointe et $P(X | Y)$ la **probabilité conditionnelle** de X sous condition de Y .
- La **probabilité jointe** peut s'écrire alors:

$$P(X, Y) = P(X | Y)P(Y) \quad (1)$$

- et la **probabilité marginale** est la somme des probabilités jointes pour toutes les valeurs de Y :

$$P(X) = \sum_Y P(X, Y) = \sum_Y (P(X|Y)P(Y)) \quad (2)$$

2.4 Analyse discriminante linéaire - règle Bayésienne 2/4

- Comme $P(X, Y) = P(Y, X)$ on obtient directement le théorème Bayésien:

$$P(Y | X) = \frac{P(X | Y)P(Y)}{P(X)} \quad (3)$$

- Ici X et Y sont des variables discrètes, mais une règle presque identique peut être définie pour des variables continues. Pour cela il faut remplacer les probabilités par des densités de probabilité.

2.4 Analyse discriminante linéaire - règle Bayésienne 3/4

- **Probabilité postérieure:** Soit $\vec{x} \in \mathbb{R}^P$ avec une densité de probabilité $p(\vec{x})$ et $y \in \{1 \dots, K\}$ une variable discrète. La probabilité a posteriori $P(y = k | \vec{x})$ est donc :

$$P(y = k | \vec{x}) = \frac{p(\vec{x} | y = k)P(y = k)}{p(\vec{x})} \quad (4)$$

- **La règle Bayésienne de classification:** *Choisis la classe qui maximise $P(y = k | \vec{x})$:*

$$\hat{y}(\vec{x}) = \arg \max_k P(y = k | \vec{x}) = \arg \max_k p(\vec{x} | y = k)P(y = k) \quad (5)$$

2.4 Analyse discriminante linéaire - règle Bayésienne 4/4

- La règle Bayésienne de classification simplement dit que la meilleure classe à choisir est celle avec la plus grande probabilité étant donné l'observation.
- Cette probabilité peut être estimée à partir de la distribution des observations pour la classe et de la probabilité *a priori*.
- Cette règle est importante parce qu'elle donne le meilleur classifieur possible, si l'on connaît les distributions des observations $p(\vec{x} | y = k)$ et les probabilités *a priori* $P(y = k)$.
- Malheureusement, ce n'est pas le cas en général. Ces distributions doivent être estimées à partir des données d'apprentissage.

2.4 Analyse discriminante linéaire - cas binaire


- On assume que l'on essaie de résoudre un problème binaire, cad $y \in \{1, 2\}$. La règle Bayésienne dit alors qu'il faut choisir la classe 1 si :

$$\frac{p(\vec{x}|y = 1)P(y = 1)}{p(\vec{x}|y = 2)P(y = 2)} > 1$$

- On peut appliquer le $\log$ aux deux côté de cette équation. On obtient donc l'expression suivante :

$$\log \frac{p(\vec{x}|y = 1)P(y = 1)}{p(\vec{x}|y = 2)P(y = 2)} > 0 \quad (6)$$

2.4 Analyse discriminante linéaire - Supposition de normalité



- On suppose que les descripteurs sont distribués normalement pour chacune des classes :

$$p(\vec{x}|y = k) = \frac{1}{(2\pi)^{\frac{p}{2}} |\Sigma_k|^{\frac{1}{2}}} e^{-\frac{1}{2}(\vec{x}-\mu_k)^T \Sigma_k^{-1}(\vec{x}-\mu_k)} \quad (7)$$

Analyse discriminante linéaire

- Avec les expressions (??) et (??) et l'hypothèse supplémentaire que les matrices de covariance sont identiques pour toutes les classes, cad $\Sigma_1 = \Sigma_2 = \Sigma$, on obtien l'analyse discriminante linéaire **Linear Discriminant Analysis, LDA**:

$$K + \vec{x}^T \Sigma^{-1}(\mu_1 - \mu_2) - \frac{1}{2}(\mu_1 - \mu_2)^T \Sigma^{-1}(\mu_1 + \mu_2) > 0$$

avec $K = \log \frac{P(y=1)}{P(y=2)} + \frac{1}{2} \log \frac{|\Sigma_2|}{|\Sigma_1|}$

- On observe :
 - Il s'agit d'un classifieur linéaire.
 - L'expression implique l'inversion d'une matrice de covariance (instable pour des descripteurs corrélés).