

Formation Chef de Projet IA

Fondamentaux du Machine Learning

Thomas Walter Chloé-Agathe Azencott Florian Massip

Center for Computational Biology (CBIO)
Mines Paris – Institut Curie – INSERM U900
PSL Research University & PR[AI]RIE, Paris, France

November 26, 2025

Programme

- Introduction à l'apprentissage automatique
- **Cours 1** : Minimisation du risque empirique
- **Cours 2** : Régularisation et sélection de modèle
- **Cours 3** : Arbres et méthodes ensemblistes
- **Cours 4** : Méthodes à noyaux
- **Cours 5** : Réduction de dimension
- **Cours 6** : Clustering
- Travaux pratiques : mise en œuvre des notions et algorithmes avec scikit-learn (Python numérique).

Qu'est-ce que l'intelligence artificielle ?

Qu'est-ce que l'intelligence artificielle ?

- Dartmouth Conference, 1956

The science and engineering of making computers behave in ways that, until recently, we thought required human intelligence.

- Reproduire **artificiellement** les comportements du vivant **perçus comme intelligents**

Qu'est-ce que l'intelligence artificielle ?

- Dartmouth Conference, 1956

The science and engineering of making computers behave in ways that, until recently, we thought required human intelligence.

- Reproduire **artificiellement** les comportements du vivant **perçus comme intelligents**
- **Effet IA:** "Intelligent est tout ce qui n'est pas encore fait par un ordinateur."

Qu'est-ce que l'intelligence artificielle ?

- Dartmouth Conference, 1956

The science and engineering of making computers behave in ways that, until recently, we thought required human intelligence.

- Reproduire **artificiellement** les comportements du vivant **perçus comme intelligents**
- **Effet IA:** "Intelligent est tout ce qui n'est pas encore fait par un ordinateur."



Intelligence Artificielle (IA) - Motivations



Figure: Talos: un automate en bronze, gardien de Crète

- Fascination scientifique
- Comprendre l'intelligence naturelle
- Outils de support dans nos tâches quotidiennes
 - Automatisation
 - Faire ce qui est infaisable pour un humain

Quelques sous-domaines de l'IA

- **Robotique**
 - mécanique, électronique, contrôle
- **Systèmes experts**
 - utilisent des règles
 - logique des propositions, logique des prédicats
- **Traitement du langage naturel**
- **Vision par ordinateur**
- **Informatique affective**
 - reconnaître, modéliser, exprimer les émotions humaines
 - sciences cognitives, psychologie
- Apprentissage automatique

Apprentissage automatique

- Apprendre :

Apprentissage automatique

- **Apprendre** : acquérir une **compétence** par l'**expérience**, la pratique.
- Pour une machine :
 - **compétence** = algorithme
 - **expérience**, pratique = exemples, données

Apprentissage automatique

- **Apprendre** : acquérir une **compétence** par l'**expérience**, la pratique.
- Pour une machine :
 - **compétence** = algorithme
 - **expérience**, pratique = exemples, données
- Autres noms : apprentissage statistique ; machine learning.


Algorithme d'apprentissage

- **Algorithme classique :**




Algorithme d'apprentissage

- **Algorithme classique :**




Algorithme d'apprentissage

- **Algorithme classique :**



- **Algorithme d'apprentissage :**



Deep learning, ML et IA

- La plupart des succès récents de l'« intelligence artificielle » sont en fait des progrès en **apprentissage automatique**.

Il s'agit d'utiliser (beaucoup) d'exemples d'une tâche pour apprendre à faire cette tâche

- La plupart de ces progrès sont des progrès en **apprentissage profond** (deep learning) : un des domaines de l'apprentissage automatique qui utilise des **réseaux de neurones à plusieurs couches**.

Deep learning

- **Exemples**
 - **Traitement automatique d'images** : reconnaître si une photo contient un chat / est celle d'une personne spécifique / est un échantillon histopathologique d'une tumeur
 - **Traitement automatique du langage** : traduction automatique, chatbots
 - **Génération automatique** de texte, d'images, de son, de vidéos réalistes (en particulier deepfakes)
- **Ingrédients du succès** :
 - Énormes **quantités de données**
 - **Puissance de calcul**
 - Compréhension des données et problèmes
⇒ modélisation (= **formulation** du problème) et architecture appropriées.

Autres exemples d'application du ML

- Détection de fraude
- Segmentation de marché
- Contrôle qualité
- Maintenance prédictive
- Systèmes de recommandation
- Trading algorithmique
- Assistance au diagnostic
- Médecine prédictive
- Et beaucoup, beaucoup d'autres.

Défis actuels du ML

- Apprendre à partir de **peu d'exemples**

Un enfant ou un animal n'a pas besoins de milliers/millions d'exemples pour apprendre

- Résoudre des problèmes **que l'humain ne sait pas résoudre**

Utilisation dans la recherche scientifique (biologie, santé, chimie, science des matériaux, astrophysique, etc.)

- **Confiance**

validation formelle, explicabilité, robustesse aux attaques

- **Questions éthiques**

biais algorithmiques ; coûts environnementaux ; équité et moralité

1. Types de problèmes d'apprentissage automatique

1.1 Apprentissage supervisé



- **But :** apprendre un modèle prédictif

1.1 Apprentissage supervisé



- **But** : apprendre un modèle **prédictif**
- **Formalisation** :

Données :

- n observations $\{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n\}$; $\vec{x}_i \in \mathcal{X} = \mathbb{R}^p$
- n étiquettes $\{y_1, y_2, \dots, y_n\}$; $y_i \in \mathcal{Y}$

Sortie :

- **modèle** $f : \mathcal{X} \rightarrow \mathcal{Y}$ tel que $f(\vec{x}_i) \approx y_i$.

1.1 Apprentissage supervisé



- **But** : **apprendre** un modèle **prédictif**
- **Formalisation** :

Données :

- n observations $\{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n\}; \vec{x}_i \in \mathcal{X} = \mathbb{R}^p$
- n étiquettes $\{y_1, y_2, \dots, y_n\}; y_i \in \mathcal{Y}$
 - **Régression** : $\mathcal{Y} = \mathbb{R}$

Sortie :

- **modèle** $f : \mathcal{X} \rightarrow \mathcal{Y}$ tel que $f(\vec{x}_i) \approx y_i$.

1.1 Apprentissage supervisé



- **But** : **apprendre** un modèle **prédictif**
- **Formalisation** :

Données :

- n observations $\{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n\}$; $\vec{x}_i \in \mathcal{X} = \mathbb{R}^p$
- n étiquettes $\{y_1, y_2, \dots, y_n\}$; $y_i \in \mathcal{Y}$
 - **Régression** : $\mathcal{Y} = \mathbb{R}$
 - **Classification** : $\mathcal{Y} = \{0, 1, \dots, C - 1\}$

Sortie :

- **modèle** $f : \mathcal{X} \rightarrow \mathcal{Y}$ tel que $f(\vec{x}_i) \approx y_i$.

1.1 Apprentissage supervisé



- **But** : **apprendre** un modèle **prédictif**
- **Formalisation** :

Données :

- n observations $\{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n\}; \vec{x}_i \in \mathcal{X} = \mathbb{R}^p$
- n étiquettes $\{y_1, y_2, \dots, y_n\}; y_i \in \mathcal{Y}$
 - **Régression** : $\mathcal{Y} = \mathbb{R}$
 - **Classification** : $\mathcal{Y} = \{0, 1, \dots, C - 1\}$
 - **Classification binaire** : $\mathcal{Y} = \{0, 1\}$

Sortie :

- **modèle** $f : \mathcal{X} \rightarrow \mathcal{Y}$ tel que $f(\vec{x}_i) \approx y_i$.

1.1 Apprentissage supervisé



- **But** : **apprendre** un modèle **prédictif**
- **Formalisation** :

Données :

- n observations $\{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n\}$; $\vec{x}_i \in \mathcal{X} = \mathbb{R}^p$
- n étiquettes $\{y_1, y_2, \dots, y_n\}$; $y_i \in \mathcal{Y}$
 - **Régression** : $\mathcal{Y} = \mathbb{R}$
 - **Classification** : $\mathcal{Y} = \{0, 1, \dots, C - 1\}$
 - **Classification binaire** : $\mathcal{Y} = \{0, 1\}$

Sortie :

- **modèle** $f : \mathcal{X} \rightarrow \mathcal{Y}$ tel que $f(\vec{x}_i) \approx y_i$.
- **Inférence** : étant donné $\vec{x} \in \mathcal{X}$, prédire $\hat{y} = f(\vec{x})$.

Exemples

- Exemples de **problèmes de régression** : $\mathcal{Y} = \mathbb{R}$
 - **Prédiction de clics** : combien de personnes vont cliquer sur ce lien ?
 - Prédiction de la **solubilité d'une molécule** dans l'éthanol en mg/mL

Exemples

- Exemples de **problèmes de régression** : $\mathcal{Y} = \mathbb{R}$
 - **Prédiction de clics** : combien de personnes vont cliquer sur ce lien ?
 - Prédiction de la **solubilité d'une molécule** dans l'éthanol en mg/mL
- Exemples de **problèmes de classification binaire** : $\mathcal{Y} = \{0, 1\}$
 - **Filtrage de spam** : cet email est-il un spam ?
 - **Reconnaissance faciale**

Exemples

- Exemples de **problèmes de régression** : $\mathcal{Y} = \mathbb{R}$
 - **Prédiction de clics** : combien de personnes vont cliquer sur ce lien ?
 - Prédiction de la **solubilité d'une molécule** dans l'éthanol en mg/mL
- Exemples de **problèmes de classification binaire** : $\mathcal{Y} = \{0, 1\}$
 - **Filtrage de spam** : cet email est-il un spam ?
 - **Reconnaissance faciale**
- Exemples de **problèmes de classification multiclasse** :
 - **OCR**, reconnaissance de chiffres manuscrits : $\mathcal{Y} = \{0, 1, 2, \dots, 9\}$
 - Reconnaissance de **plantes** ou de **chants d'oiseaux**

1.2 Apprentissage non supervisé



- **But :** explorer les données ; apprendre une nouvelle représentation

1.2 Apprentissage non supervisé



- **But : explorer** les données ; apprendre une nouvelle représentation
- **Formalisation :**

Données :

n observations $\{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n\} ; \vec{x}_i \in \mathcal{X} = \mathbb{R}^p$

Sortie :

1.2 Apprentissage non supervisé



- **But : explorer** les données ; apprendre une nouvelle représentation

- **Formalisation :**

Données :

n observations $\{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n\} ; \vec{x}_i \in \mathcal{X} = \mathbb{R}^p$

Sortie :

- **Réduction de dimension :** $f : \mathbb{R}^p \rightarrow \mathbb{R}^d$ avec $d \ll p$ et de telle sorte à ce que $f(\vec{x})$ soit une **représentation informative** de $\vec{x}$

1.2 Apprentissage non supervisé



- **But : explorer** les données ; apprendre une nouvelle représentation
- **Formalisation :**

Données :

n observations $\{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n\} ; \vec{x}_i \in \mathcal{X} = \mathbb{R}^p$

Sortie :

- **Réduction de dimension :** $f : \mathbb{R}^p \rightarrow \mathbb{R}^d$ avec $d \ll p$ et de telle sorte à ce que $f(\vec{x})$ soit une **représentation informative** de $\vec{x}$
- **Clustering :** partition de $\{1, 2, \dots, n\}$ en ensembles d'éléments semblables, appelés **clusters**

1.2 Apprentissage non supervisé



- **But : explorer** les données ; apprendre une nouvelle représentation
- **Formalisation :**

Données :

n observations $\{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n\} ; \vec{x}_i \in \mathcal{X} = \mathbb{R}^p$

Sortie :

- **Réduction de dimension :** $f : \mathbb{R}^p \rightarrow \mathbb{R}^d$ avec $d \ll p$ et de telle sorte à ce que $f(\vec{x})$ soit une **représentation informative** de $\vec{x}$
- **Clustering :** partition de $\{1, 2, \dots, n\}$ en ensembles d'éléments semblables, appelés **clusters**
- **Estimation de densité :** la loi de probabilité de X dont $\{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n\}$ est supposé être un échantillon.

Réduction de dimension

Apprendre $f : \mathbb{R}^p \rightarrow \mathbb{R}^d$ avec $d \ll p$ et de telle sorte à ce que $f(\vec{x})$ soit une **représentation informative** de $\vec{x}$

- **Utilisation :**

- Visualiser les données (en particulier $d = 2$)
- Réduire la taille des données en mémoire
- Améliorer la performance d'un algorithme supervisé

Clustering

Apprendre une partition de $\{1, 2, \dots, n\}$ en ensembles d'éléments semblables, appelés **clusters**

- **Exemples d'application :**

- **Segmentation de marché :** regrouper des clients qui ont des profils similaires
- **Topic modeling:** regrouper les documents d'un corpus par thème ; les thèmes émergent de l'analyse et ne sont pas fournis.

1.3 Autres problèmes d'apprentissage

- **Apprentissage semi-supervisé**

Une partie seulement des données est étiquetée

- **Apprentissage par renforcement**

Définir une **politique** permettant de maximiser sa **récompense**

- **Régression structurée**

Apprentissage supervisé avec $\mathcal{Y}$ un espace de vecteurs, de séquences, de texte, de graphes etc.

2. Premier exemple : les plus proches voisins

2.1 Algorithme du plus proche voisin

- **Données :** $\mathcal{D} = \{(\vec{x}_1, y_1), (\vec{x}_2, y_2), \dots, (\vec{x}_n, y_n)\}$
 - n observations en p dimensions : $\vec{x}_i \in \mathbb{R}^p$
 - n étiquettes : $y_i \in \mathcal{Y}$

2.1 Algorithme du plus proche voisin


- **Données :** $\mathcal{D} = \{(\vec{x}_1, y_1), (\vec{x}_2, y_2), \dots, (\vec{x}_n, y_n)\}$
 - n observations en p dimensions : $\vec{x}_i \in \mathbb{R}^p$
 - n étiquettes : $y_i \in \mathcal{Y}$
- **Modèle :** Associer à $\vec{x} \in \mathbb{R}^p$ l'étiquette de l'exemple dans $\mathcal{D}$ dont $\vec{x}$ est le plus proche selon la distance euclidienne

$$f(\vec{x}) = y_{\arg \min_{i=1, \dots, n} \|\vec{x} - \vec{x}_i\|_2}$$

2.1 Algorithme du plus proche voisin

- **Données :** $\mathcal{D} = \{(\vec{x}_1, y_1), (\vec{x}_2, y_2), \dots, (\vec{x}_n, y_n)\}$
 - n observations en p dimensions : $\vec{x}_i \in \mathbb{R}^p$
 - n étiquettes : $y_i \in \mathcal{Y}$
- **Modèle :** Associer à $\vec{x} \in \mathbb{R}^p$ l'étiquette de l'exemple dans $\mathcal{D}$ dont $\vec{x}$ est le plus proche selon la distance euclidienne

$$f(\vec{x}) = y_{\arg \min_{i=1, \dots, n} \|\vec{x} - \vec{x}_i\|_2}$$



2.1 Algorithme du plus proche voisin

- **Données :** $\mathcal{D} = \{(\vec{x}_1, y_1), (\vec{x}_2, y_2), \dots, (\vec{x}_n, y_n)\}$
 - n observations en p dimensions : $\vec{x}_i \in \mathbb{R}^p$
 - n étiquettes : $y_i \in \mathcal{Y}$
- **Modèle :** Associer à $\vec{x} \in \mathbb{R}^p$ l'étiquette de l'exemple dans $\mathcal{D}$ dont $\vec{x}$ est le plus proche selon la distance euclidienne

$$f(\vec{x}) = y_{\arg \min_{i=1, \dots, n} \|\vec{x} - \vec{x}_i\|_2}$$

- Régression, classification binaire, classification multiclasse.

2.1 Algorithme du plus proche voisin

- **Données :** $\mathcal{D} = \{(\vec{x}_1, y_1), (\vec{x}_2, y_2), \dots, (\vec{x}_n, y_n)\}$
 - n observations en p dimensions : $\vec{x}_i \in \mathbb{R}^p$
 - n étiquettes : $y_i \in \mathcal{Y}$
- **Modèle :** Associer à $\vec{x} \in \mathbb{R}^p$ l'étiquette de l'exemple dans $\mathcal{D}$ dont $\vec{x}$ est le plus proche selon la distance euclidienne

$$f(\vec{x}) = y_{\arg \min_{i=1, \dots, n} \|\vec{x} - \vec{x}_i\|_2}$$

- Régression, classification binaire, classification multiclasse.
- **Pas de phase d'apprentissage !**

2.2 kNN pour la classification

- L'algorithme du plus proche voisin est **peu robuste** au bruit
- Plutôt que d'utiliser **le** plus proche voisin : utiliser les k observations les plus proches
- **Vote de la majorité** : on donne à $\vec{x}$ **l'étiquette majoritaire** parmi ses k plus proches voisins

2.2 kNN pour la classification

- L'algorithme du plus proche voisin est **peu robuste** au bruit
- Plutôt que d'utiliser **le** plus proche voisin : utiliser les k observations les plus proches
- **Vote de la majorité** : on donne à $\vec{x}$ **l'étiquette majoritaire** parmi ses k plus proches voisins

$$f(\vec{x}) = \arg \max_{c \in \{0,1,\dots,C-1\}} \sum_{i: \vec{x}_i \in \mathcal{N}_k(\vec{x})} \delta(y_i, c)$$

- $\mathcal{N}_k(\vec{x})$ est l'ensemble des k plus proches voisins de $\vec{x}$ dans $\mathcal{D}$
- $\delta(y_i, c) = 1$ si $y_i = c$ et 0 sinon; C est le nombre de classes.

2.2 kNN pour la classification

- L'algorithme du plus proche voisin est **peu robuste** au bruit
- Plutôt que d'utiliser **le** plus proche voisin : utiliser les k observations les plus proches
- **Vote de la majorité** : on donne à $\vec{x}$ **l'étiquette majoritaire** parmi ses k plus proches voisins

$$f(\vec{x}) = \arg \max_{c \in \{0,1,\dots,C-1\}} \sum_{i: \vec{x}_i \in \mathcal{N}_k(\vec{x})} \delta(y_i, c)$$

- $\mathcal{N}_k(\vec{x})$ est l'ensemble des k plus proches voisins de $\vec{x}$ dans $\mathcal{D}$
 - $\delta(y_i, c) = 1$ si $y_i = c$ et 0 sinon; C est le nombre de classes.
- Pour la classification binaire, on utilise un nombre **impair** de voisins pour ne pas avoir d'ex-aequo.

2.3 kNN pour la régression

- **Moyenne** : on donne à $\vec{x}$ la moyenne des étiquettes de ses k plus proches voisins

$$f(\vec{x}) = \frac{1}{k} \sum_{i: \vec{x}_i \in \mathcal{N}_k(\vec{x})} y_i$$

2.3 kNN pour la régression

- **Moyenne** : on donne à $\vec{x}$ la **moyenne des étiquettes** de ses k plus proches voisins

$$f(\vec{x}) = \frac{1}{k} \sum_{i: \vec{x}_i \in \mathcal{N}_k(\vec{x})} y_i$$

- **Remarque** : Les modèles donnés par des algorithmes de plus proches voisins sont des modèles **non-paramétriques** :
 - il ne s'agit pas d'apprendre les paramètres d'une expression explicite des variables $x_1, \dots, x_p$
 - par opposition aux **modèles linéaires** et aux **réseaux de neurones**
 - k est un **hyperparamètre** : l'algorithme ne permet pas de l'apprendre.

2.4 Variantes

- **Epsilon-voisins** Au lieu de considérer k voisins les plus proches, on considère toutes les observations contenues dans une boule de rayon ϵ centrée sur $\vec{x}$.
- **Pondérations des voisins** La contribution de chaque voisin est pondérée par un coefficient inversement proportionnel à sa distance à $\vec{x}$.
- **Autres distances** L'algorithme s'applique aussi en considérant d'autres distances / notions de similarité :
 - Distance de Minkowski
 - Similarité cosinus
 - Distance de Hamming entre vecteurs binaires