Formation Chef de Projet IA

Fondamentaux du Machine Learning

Thomas Walter Chloé-Agathe Azencott

Center for Computational Biology (CBIO)
Mines Paris – Institut Curie – INSERM U1331
PSL Research University & PR[AI]RIE, Paris, France

October 15, 2026

Programme

- Introduction à l'apprentissage automatique
- **Cours 1 :** Minimisation du risque empirique
- **Cours 2 :** Régularisation et sélection de modèle
- **Cours 3 :** Arbres et méthodes ensemblistes
- **Cours 4 :** Méthodes à noyaux
- **Cours 5 :** Réduction de dimension
- **Cours 6 :** Clustering
- Travaux pratiques : mise en œuvre des notions et algorithmes avec scikit-learn (Python numérique).

Cours 6 – Clustering

Clustering ou partitionnement

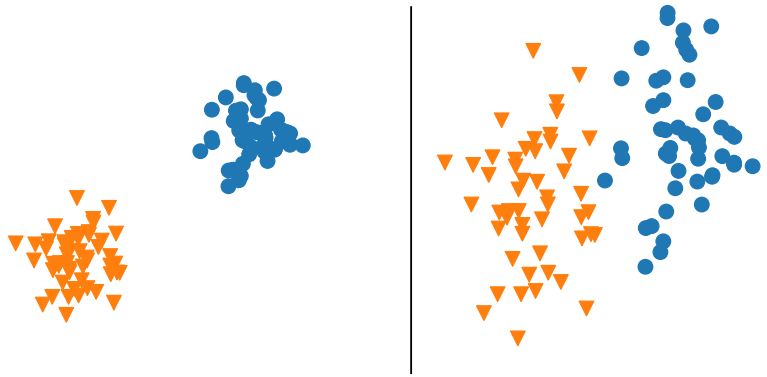
- **Clustering :** partitionner les données en sous-ensembles (**clusters**) homogènes
- Exemples :
  - **segmentation de marché**
  - **communautés** sur un réseau social
  - **topic modeling** (thématique de textes)
  - **compression** ou **segmentation d'images**
  - **sous-types** d'une maladie

Clustering : Motivation

- Étude de données **non-étiquetées**
- Analyse **exploratoire**
- **Visualisation**
- Peut précéder une phase d'**inférence**

1. Évaluation d'un clustering

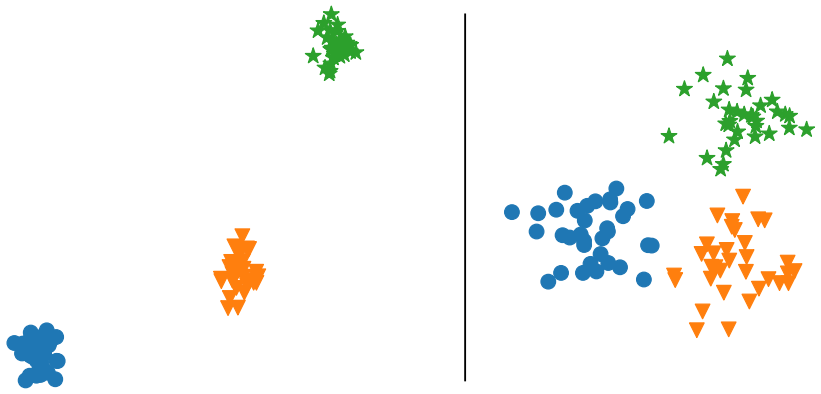
1.1 Critères géométriques



- Définition centroïde du cluster $\mathcal{C}$: $\vec{\mu}_{\mathcal{C}} = \frac{1}{\mathcal{C}} \sum_{\vec{x} \in \mathcal{C}} \vec{x}$
- Définition médoïde du cluster $\mathcal{C}$: $\vec{m}_{\mathcal{C}} = \arg\min_{\vec{x} \in \mathcal{C}} d(\vec{x}, \vec{\mu}_{\mathcal{C}})$
- **Dispersion** d'un cluster k : $T_k = \frac{1}{|\mathcal{C}_k|} \sum_{\vec{x} \in \mathcal{C}_k} d(\vec{x}, \vec{\mu}_k)$
- Dispersion d'un clustering :

$$T = \frac{1}{K} \sum_{k=1}^{K} T_k$$

1.1 Critères géométriques



- Séparabilité des clusters k et l :

$$s_{kl} = d(\vec{\mu}_k, \vec{\mu}_l)$$

- Séparabilité d'un clustering :

$$S = \frac{2}{K(K-1)} \sum_{k=1}^{K-1} \sum_{l=k+1}^{K} s_{kl}$$

1.1 Critères géométriques

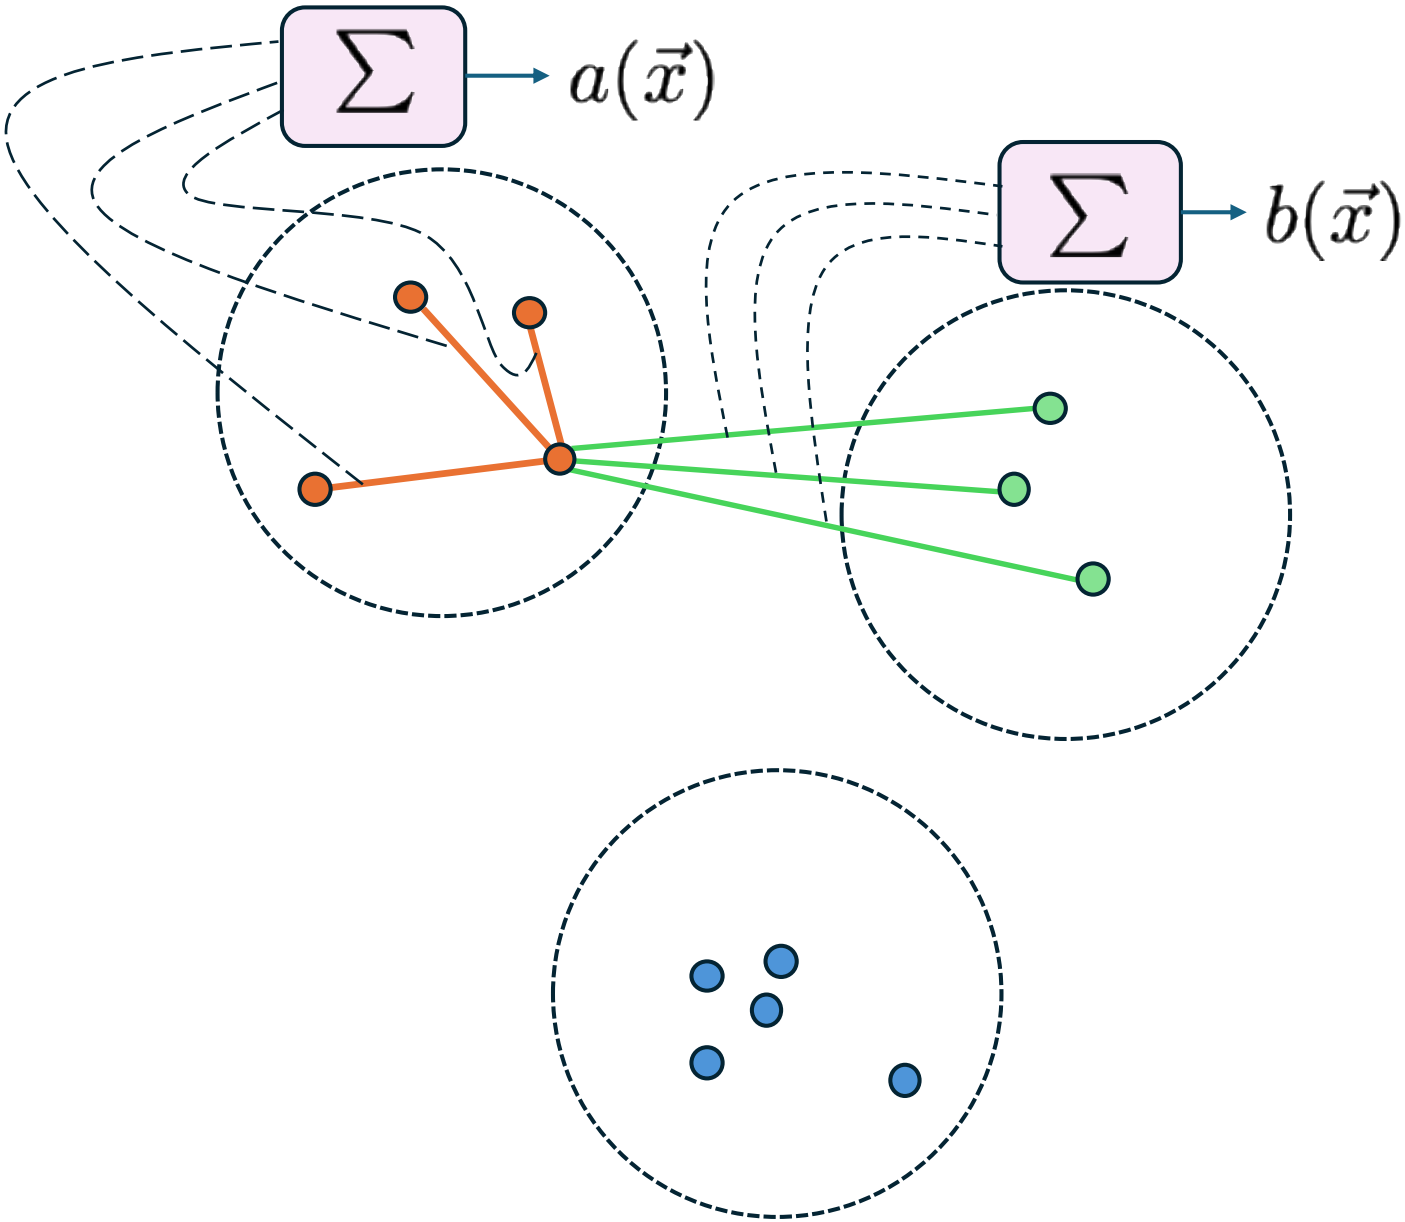
– **Coefficient de silhouette.** On note d'abord $a(\vec{x})$ la moyenne des distances entre $\vec{x}$ et les autres points du cluster $k(\vec{x})$ auquel $\vec{x}$ est assigné :

$$a(\vec{x}) = \frac{1}{|\mathcal{C}_{k(\vec{x})}| - 1} \sum_{\vec{u} \in \mathcal{C}_{k(\vec{x})}} d(\vec{x}, \vec{u})$$

– La quantité $b(\vec{x})$ est définie comme la plus petite valeur moyenne des distances entre $\vec{x}$ et tous les points d'un autre cluster $l \neq k(\vec{x})$:

$$b(\vec{x}) = \min_{l \neq k(\vec{x})} \frac{1}{|\mathcal{C}_l|} \sum_{u \in \mathcal{C}_l} d(\vec{u}, \vec{x})$$

Coefficient de silhouette



1.1 Critères géométriques

- Avec a et b définis ainsi, nous pouvons définir le coefficient de silhouette pour le point $\vec{x}$:

$$s(\vec{x}) = \frac{b(\vec{x}) - a(\vec{x})}{\max\left(b(\vec{x}), a(\vec{x})\right)}$$

- Finalement, le **coefficient de silhouette** pour le clustering est :

$$s = \frac{1}{n} \sum_{i=1}^{n} s(\vec{x}^i)$$

1.2 Comparaison à des étiquettes connues

– Difficulté : les clusters sont numérotés arbitrairement.

1.2 Comparaison à des étiquettes connues

- Difficulté : les clusters sont numérotés arbitrairement.
- **Indice de Rand** : pourcentage de paires de points qui sont soit dans le même cluster dans les deux partitions, soit dans des clusters différents dans les deux partitions :

$$\mathrm{RI} = \frac{2}{n(n-1)} \sum_{i=1}^{n} \sum_{l=i+1}^{n} \mathbb{1}_{k(\vec{x}^i)=k(\vec{x}^l)} \, \mathbb{1}_{y^i=y^l} + \mathbb{1}_{k(\vec{x}^i)\neq k(\vec{x}^l)} \, \mathbb{1}_{y^i\neq y^l}.$$

- Problème du RI : deux partitions aléatoires peuvent avoir un RI élevé par hasard.
- Solution : ARI (adjusted Rand index) est le RI corrigé.

1.2 Comparaison à des étiquettes connues

- Difficulté : les clusters sont numérotés arbitrairement.
- **Indice de Rand** : pourcentage de paires de points qui sont soit dans le même cluster dans les deux partitions, soit dans des clusters différents dans les deux partitions :

$$\mathrm{RI} = \frac{2}{n(n-1)} \sum_{i=1}^{n} \sum_{l=i+1}^{n} \mathbb{1}_{k(\vec{x}^i)=k(\vec{x}^l)} \, \mathbb{1}_{y^i=y^l} + \mathbb{1}_{k(\vec{x}^i)\neq k(\vec{x}^l)} \, \mathbb{1}_{y^i\neq y^l}.$$

- Problème du RI : deux partitions aléatoires peuvent avoir un RI élevé par hasard.
- Solution : ARI (adjusted Rand index) est le RI corrigé.

1.3 Stabilité des clusters

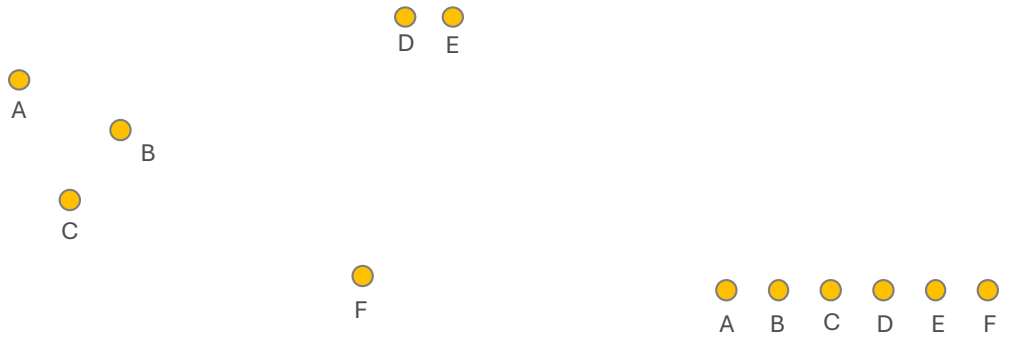
- Génération de plusieurs partitions avec le même algorithme de clustering en variant :
  - les conditions initiales de l'algorithme
  - des sous-échantillonages dans $\mathcal{D}$
  - des sous-ensembles de descripteurs (éventuellement)
- On compare les résultats de clustering.
- Dans un clustering robuste, les résultats ne devraient pas varier trop.

2. Clustering hiérarchique

Construction

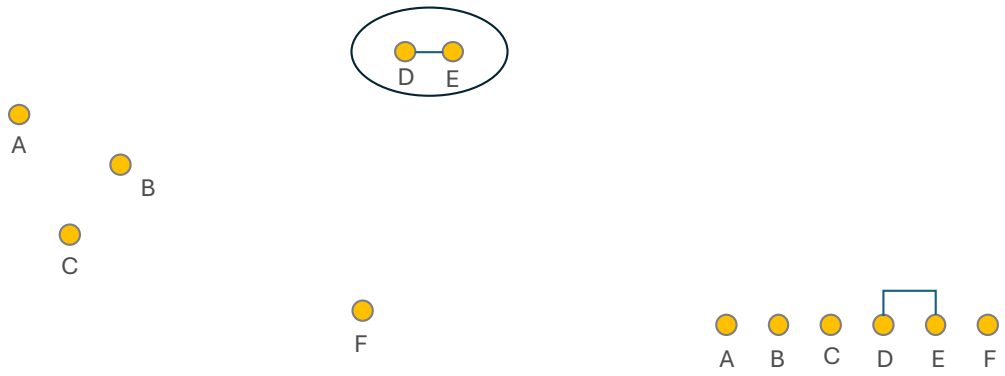
- Construction **agglomérative** (bottom-up)
  - Initialement : chaque point est son propre cluster
  - On fusionne itérativement les clusters les plus proches
- Construction **divisive** (top-down)
  - Intialement : tous les points sont dans le même cluster
  - On sépare itérativement les clusters en deux

Clustering hiérarchique – Principe



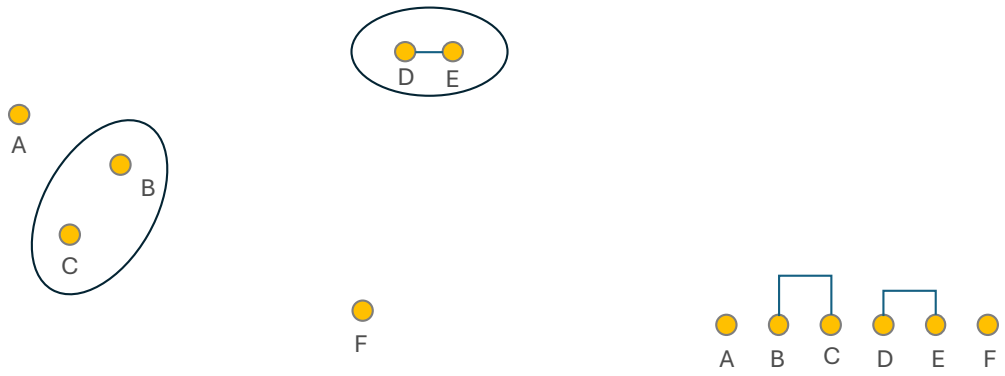
Initialisation : chaque point constitue son propre cluster.

Clustering hiérarchique – Principe



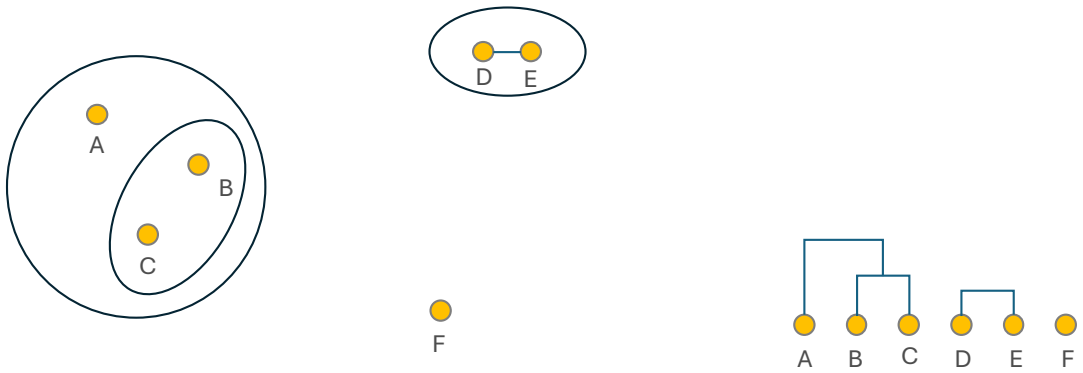
Les deux points les plus proches sont fusionnés et forment le premier cluster.

Clustering hiérarchique – Principe



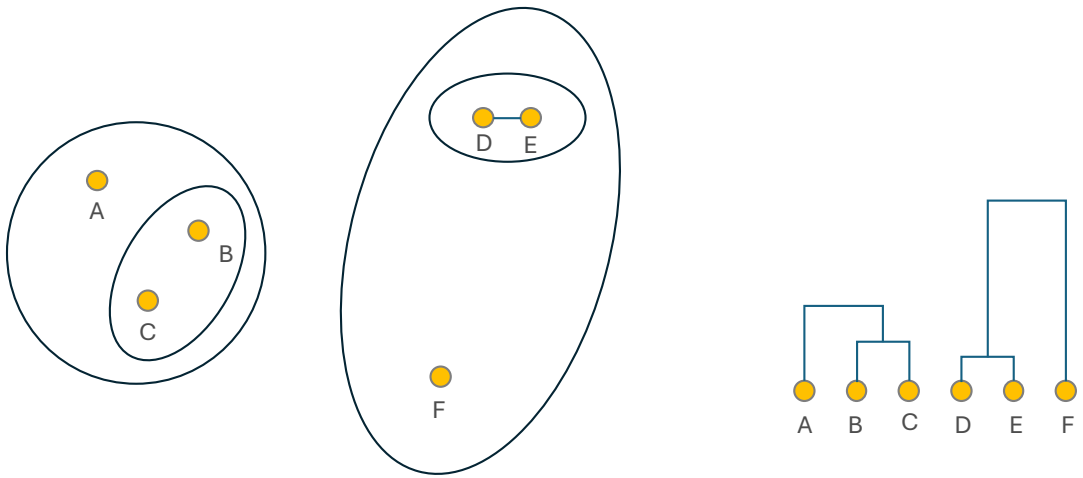
Ensuite, les points ou clusters les plus proches sont fusionnés pour former un nouveau cluster.

Clustering hiérarchique – Principe



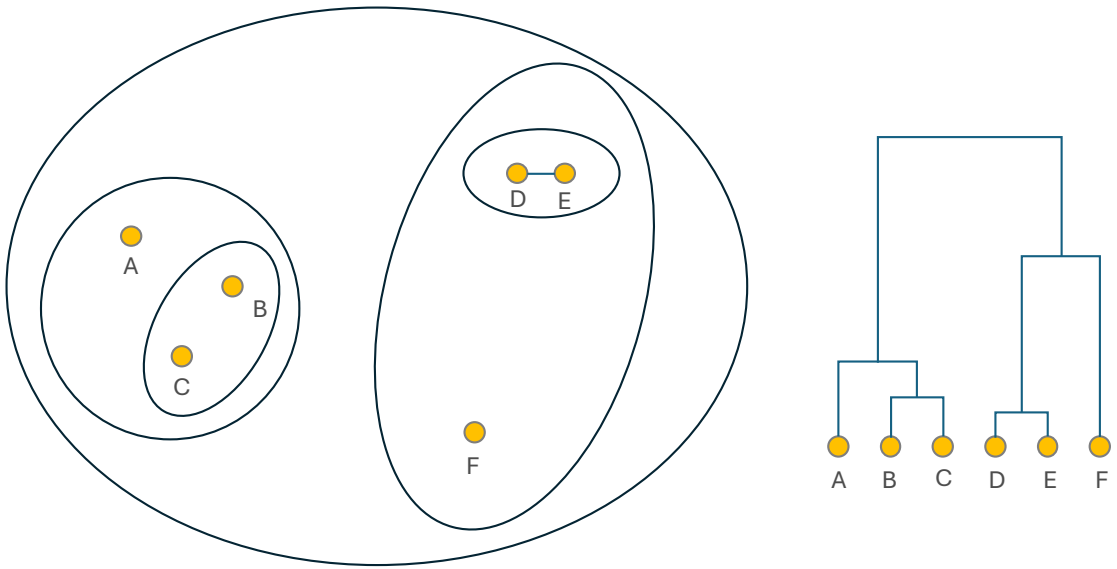
Un dendrogramme est construit afin de garder la trace des fusions successives.

Clustering hiérarchique – Principe



La hauteur de chaque fusion correspond à la distance à laquelle cette fusion a lieu.

Clustering hiérarchique – Principe



Le clustering s'arrête lorsque tous les points appartiennent à un unique cluster global.

Clustering hiérarchique – Deux ingrédients

- Distance entre les points :
  - Rappel : chaque échantillon $\vec{x}_i$ correspond à un point dans l'espace des caractéristiques.
  - Comment calculer la distance entre deux points, c'est-à-dire entre deux échantillons ?
- Distance entre les clusters :
  - Option 1 : représenter chaque cluster par un prototype et calculer une distance entre points.
  - Option 2 : calculer une agrégation des distances entre points.

Clustering hiérarchique : distances entre points

- On considère ici deux points $\vec{x}$ et $\vec{y}$; les indices désignent les composantes des vecteurs.
- **Distance euclidienne** $d(\vec{x}, \vec{y}) = \sqrt{\sum_i (\vec{x}_i - \vec{y}_i)^2}$
- **Distance de Manhattan** $d(\vec{x}, \vec{y}) = \sum_i |\vec{x}_i - \vec{y}_i|$
- **Distance cosinus** $d(\vec{x}, \vec{y}) = 1 - \frac{\vec{x}^\top \vec{y}}{\|\vec{x}\| \|\vec{y}\|}$
- **Distance de corrélation** $d(\vec{x}, \vec{y}) = 1 - \mathrm{corr}(\vec{x}, \vec{y})$

Fonctions de lien

- **Fonction de lien** (linkage) : distance entre deux clusters
  - **Lien simple** (single linkage)

$$d_{\text{simple}}(\mathcal{C}_k, \mathcal{C}_l) = \min_{(\vec{u},\vec{v})\in\mathcal{C}_k\times\mathcal{C}_l} d(\vec{u},\vec{v}).$$

Fonctions de lien

- **Fonction de lien** (linkage) : distance entre deux clusters
  - **Lien simple** (single linkage)

$$d_{\text{simple}}(\mathcal{C}_k, \mathcal{C}_l) = \min_{(\vec{u},\vec{v})\in\mathcal{C}_k\times\mathcal{C}_l} d(\vec{u}, \vec{v}).$$

  - **Lien complet** (complete linkage)

$$d_{\text{complet}}(\mathcal{C}_k, \mathcal{C}_l) = \max_{(\vec{u},\vec{v})\in\mathcal{C}_k\times\mathcal{C}_l} d(\vec{u}, \vec{v}).$$

Fonctions de lien

- **Fonction de lien** (linkage) : distance entre deux clusters
  - **Lien simple** (single linkage)

$$d_{\text{simple}}(\mathcal{C}_k, \mathcal{C}_l) = \min_{(\vec{u},\vec{v})\in\mathcal{C}_k\times\mathcal{C}_l} d(\vec{u},\vec{v}).$$

  - **Lien complet** (complete linkage)

$$d_{\text{complet}}(\mathcal{C}_k, \mathcal{C}_l) = \max_{(\vec{u},\vec{v})\in\mathcal{C}_k\times\mathcal{C}_l} d(\vec{u},\vec{v}).$$

  - **Lien moyen** (average linkage) ou UPGMA (Unweighted Paired Group Method with Arithmetic mean)

$$d_{\text{moyen}}(\mathcal{C}_k, \mathcal{C}_l) = \frac{1}{|\mathcal{C}_k|}\frac{1}{|\mathcal{C}_l|}\sum_{\vec{u}\in\mathcal{C}_k}\sum_{\vec{v}\in\mathcal{C}_l} d(\vec{u},\vec{v}).$$

Fonctions de lien

- **Fonction de lien** (linkage) : distance entre deux clusters
  - **Lien centroïdal** (centroid linkage)

$$d_{\text{centroidal}}(\mathcal{C}_k, \mathcal{C}_l) = d\left(\frac{1}{|\mathcal{C}_k|}\sum_{\vec{u}\in\mathcal{C}_k}\vec{u}, \frac{1}{|\mathcal{C}_l|}\sum_{\vec{v}\in\mathcal{C}_l}\vec{v}\right) = d(\vec{\mu}_k, \vec{\mu}_l).$$

3. Algorithme des k-moyennes

Variance intra-cluster

- **Variance intra-cluster**

$$\text{Var}_{\text{in}}(\mathcal{C}) = \frac{1}{|\mathcal{C}|} \sum_{\vec{x} \in \mathcal{C}} ||\vec{x} - \vec{\mu}||_2^2 \,.$$

- Minimiser la variance intra-cluster : créer des clusters **homogènes**

Algorithme de Lloyd

- **Initialisation :** choisir les $\vec{\mu}_1, \vec{\mu}_2, \ldots, \vec{\mu}_K$ parmi les données.
- **Affecter** chaque observation $\vec{x} \in \mathcal{D}$ au centroïde dont elle est le plus proche :

$$k(\vec{x}^i) = \underset{k=1,\ldots,K}{\arg\min} \left|\left|\vec{x}^i - \vec{\mu}_k\right|\right|_2^2$$

- **Recalculer** les centroïdes $\vec{\mu}_k$.
- **Répéter** jusqu'à ce que les affectations ne changent plus.

Algorithme de Lloyd

- **Avantages :**
  - Converge rapidement en pratique

Algorithme de Lloyd

- **Avantages :**
  - Converge rapidement en pratique
- **Inconvénients :**
  - Nécessité de fixer K
  - Approche **gloutonne** : pas de garantie de minimum global
  - **Stochasticité** : dépend de l'initialisation

Algorithme de Lloyd

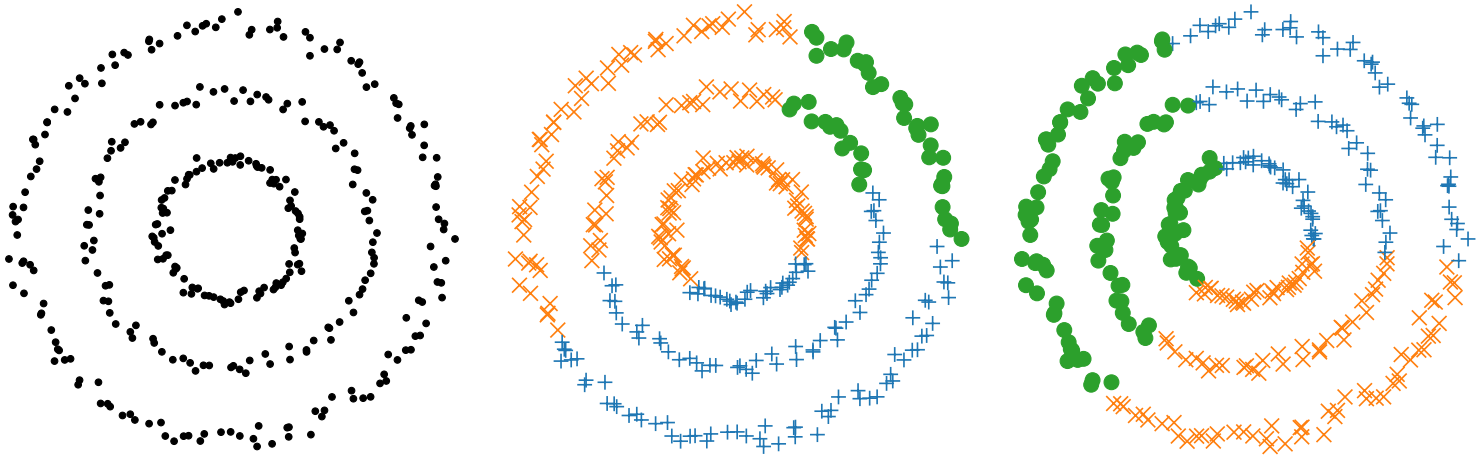
- **Avantages :**
  - Converge rapidement en pratique
- **Inconvénients :**
  - Nécessité de fixer K
  - Approche **gloutonne** : pas de garantie de minimum global
  - **Stochasticité** : dépend de l'initialisation $\longrightarrow$ k-means++
  - Clusters nécessairement **convexes**

Algorithme de Lloyd

- **Avantages :**
  - Converge rapidement en pratique
- **Inconvénients :**
  - Nécessité de fixer K
  - Approche **gloutonne** : pas de garantie de minimum global
  - **Stochasticité** : dépend de l'initialisation $\longrightarrow$ k-means++
  - Clusters nécessairement **convexes** $\longrightarrow$ kernel k-means

4. DBSCAN

DBSCAN: Motivation



Nuage de points – clustering hiérarchique – clustering kmeans

– Idée : utiliser la **densité**

DBSCAN

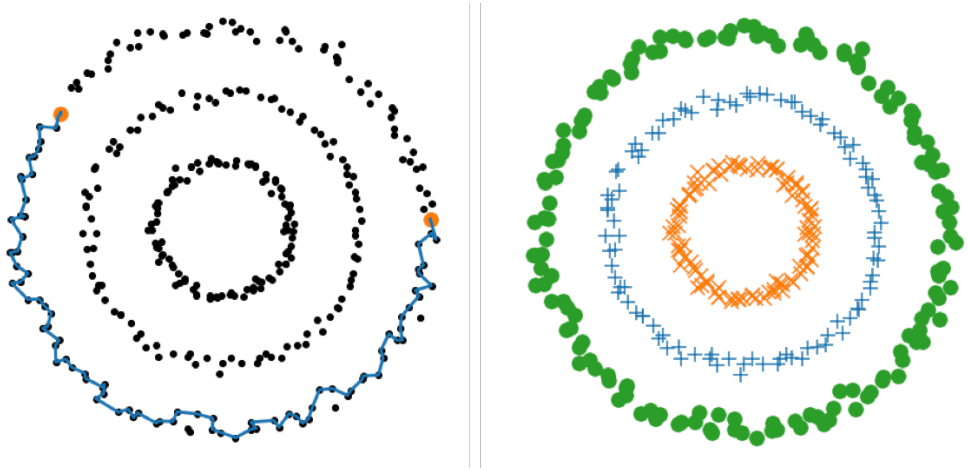
- Idée : itérer **de proche en proche** par des **voisinages** (boules) de rayon ε
- On définit deux paramètres :

1. un rayon ε
2. un number minimal de points n_{min}.

- On définit alors :
  - Point cœur (core point) : un point ayant au moins n_{min} voisins dans un rayon ε.
  - Point frontière (border point) : moins de n_{min} dans son voisinage, mais il est proche d'un point coeur.
  - Point bruit (noise / outlier) : les points isolés, considérés comme du bruit .

DBSCAN

- Etapes de l'algorithmes :
  - On trouve d'abord les points coeurs.
  - Ensuite, on construit les composantes connexes en reliant entre eux les points coeurs voisins : chaque composante constitue un cluster.
  - Ensuite on assigne chaque point frontière à une composante connexe.
  - On n'assigne pas les points bruit.



DBSCAN : avantages et inconvénients

- **Avantages :**
  - n'impose pas de forme particulière
  - simple, pas de définition du nombre de clusters
  - robustesse aux données aberrantes

DBSCAN : avantages et inconvénients

- **Avantages :**
  - n'impose pas de forme particulière
  - simple, pas de définition du nombre de clusters
  - robustesse aux données aberrantes
- **Inconvénients :**
  - ne sait pas gérer des écarts
  - peu de résultats théoriques
  - pas applicable en très haute dimension

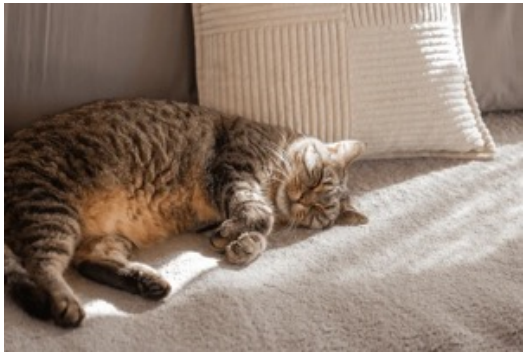
Clustering : conclusion

- Le clustering désigne le partitionnement d'un jeu de données $\{\vec{x}_i\}_{i=1..N}$ en groupes.
- Il existe de nombreuses mesures de qualité pour évaluer un clustering :
  - Mesures géométriques et séparabilité
  - Robustesse
  - Comparaison à une vérité terrain partielle
- Algorithmes :
  - Clustering hiérarchique : utile pour l'exploration
  - k-means : méthode la plus populaire, mais il faut fixer le nombre de clusters
  - DBSCAN / HDBSCAN : méthodes largement utilisées

Clustering : limites

- Il n'existe pas de méthode générale permettant d'affirmer qu'un clustering « a du sens », sauf par comparaison, systématique ou anecdotique, avec une vérité terrain.
- Structure de corrélation :
  - Des données fortement corrélées vont dominer les distances : $d(\vec{x}, \vec{y}) = \sqrt{\sum_i (x_i - y_i)^2}$
  - Utiliser une ACP pour décorréler les données ne résout pas ce problème, sauf si les composantes principales sont normalisées par rapport à leur variance, c'est-à-dire par whitening. Mais dans ce cas, on augmente aussi le bruit.
- Il n'existe pas vraiment d'approche « non supervisée » :
  - Nous choisissons les caractéristiques
  - Nous choisissons les méthodes, les distances et les hyperparamètres

Clustering : un problème mal posé


Comment définir deux groupes pour ces images ?

Conclusion générale - avant de commencer

- Spécification du problème :
  - supervisé ou non-supervisé ?
  - régression ou classification ?
- Quantification pour la mise en place:
  - combien de descripteurs (p) ?
  - combien d'échantillons annotés (n) ?
  - combien d'échantillons non-annotés ?

Conclusion générale - avant de commencer

- Exigences supplémentaires :
  - interprétabilité des modèles
  - robustesse
  - compromis sensibilité / précision
  - biais et perturbations potentiels

Conclusion générale - méthodes non-supervisées

- Exploration graphique des données :
  - Réduction de dimensions (ACP, t-SNE)
  - Clustering pour trouver des groupes
- Le but est comprendre les distributions des données et éventuellement d'identifier des groupes.
- Visualisation joue souvent un rôle clé pendant cette phase exploratoire.

Conclusion générale - problèmes supervisés

- Si $n \gg p$:
  - des méthodes classiques comme la LDA ou la régression logistique peuvent s'appliquer.
  - Problème potentiel : corrélation des descripteurs. Solution possible : sélectionner les descripteurs, ou bien appliquer une ACP.
  - Tester l'effet d'une régularisation.
- Si $p > n$ (et même si $p \gg n$):
  - les SVM ou les RF sont préférables.
  - la régularisation se fait avec la norme L_2 des paramètres pour les SVM et par ensembling pour les RF.

Références / page pub

- **Introduction au Machine Learning**, Chloé-Agathe Azencott, Dunod InfoSup
  Version électronique (PDF) sans exercices disponible gratuitement sur
  http://cazencott.info [lien cliquable]
  (nouvelle édition en préparation)
- **Le Machine Learning avec scikit-learn**, Aurélien Géron, Dunod InfoSup
- Textes et vidéos sur **OpenClassrooms :**
  Textes accessibles librement ; vidéos accessibles avec un compte gratuit.
  - Parcours Ingénieur Machine Learning [lien cliquable]
  - Objectif IA (grand public) [lien cliquable]

Ressources complémentaires

- **Sources de jeux de données**
  - Kaggle [lien cliquable]
  - Le module `datasets` de `scikit-learn` [lien cliquable]
  - Le UCI Machine Learning Repository [lien cliquable]
- **MOOC scikit-learn** [lien cliquable]