

Formation Chef de Projet IA

Fondamentaux du Machine Learning

Thomas Walter Chloé-Agathe Azencott Florian Massip


Center for Computational Biology (CBIO)
Mines Paris – Institut Curie – INSERM U900
PSL Research University & PR[AI]RIE, Paris, France
December 2, 2025

Programme

- Introduction à l'apprentissage automatique
- **Cours 1** : Minimisation du risque empirique
- **Cours 2** : Régularisation et sélection de modèle
- **Cours 3** : Arbres et méthodes ensemblistes
- **Cours 4** : Méthodes à noyaux
- **Cours 5** : Réduction de dimension
- **Cours 6** : Clustering
- Travaux pratiques : mise en œuvre des notions et algorithmes avec scikit-learn (Python numérique).


1. Machines à vecteurs de support (SVM)

1.1 SVM: le principe




- On considère des données linéairement séparables.
- Un jeu de données $\mathcal{D} = \{(\vec{x}_1, y_1), (\vec{x}_2, y_2), \dots, (\vec{x}_n, y_n)\}$ avec $y_i \in \{-1, 1\}$ est linéairement séparable, s'il existe un hyperplan tel que toutes les données avec $y_i = -1$ se trouvent d'un côté de l'hyperplan et toutes les données avec $y_i = 1$ de l'autre.

1.1 SVM: le principe




- Pour des données linéairement séparables, on place un "ruban" entre les données, c'est-à-dire un hyperplan avec ces deux parallèles h^+ et h^- .
- On appelle d la distance entre h^+ et h^- la marge du classifieur.
- Les "classifieurs à large marge" visent à maximiser d .

1.2 SVM: le cas séparable




- Hyperplan séparateur $h : \langle \vec{w}; \vec{x} \rangle + b = 0$.
- $\vec{w}$: vecteur normal de l'hyperplan séparateur. b est le biais (intercept).
- $\langle \vec{w}; \vec{x} \rangle$ est le produit scalaire du vecteur normal (vecteur des poids) avec le vecteur des descripteurs.
- Pour des descripteurs centrés réduits, $\vec{w}$ reflète l'importance des descripteurs.

1.2 SVM: le cas séparable



- $\langle \vec{w}, \vec{x} \rangle + b > 0$: $\vec{x}$ se trouve du côté vers lequel $\vec{w}$ pointe.
- $\langle \vec{w}, \vec{x} \rangle + b < 0$: $\vec{x}$ se trouve du côté opposé.
- Avec l'encodage $y \in \{-1, +1\}$, un échantillon $\vec{x}_i$ est correctement classifié si $y_i(\langle \vec{w}; \vec{x}_i \rangle + b) > 0$.

1.2 SVM: le cas séparable




- Le ruban est défini par deux hyperplans parallèles, pour lesquels $\langle \vec{w}; \vec{x} \rangle + b = \pm 1$
- La distance entre ces deux hyperplans $\langle \vec{w}; \vec{x} \rangle + b = \pm 1$ est :

$$d = \frac{2}{\|\vec{w}\|} \quad (1)$$

- Maximiser d est équivalent à minimiser $\|\vec{w}\|^2$.

1.2 SVM: le cas séparable



- Cela mène à un problème d'**optimisation convexe sous contraintes** :

$$\begin{aligned} \min \quad & \frac{1}{2} \|\vec{w}\|^2 \\ \text{t.q.} \quad & y_i (\langle \vec{w}; \vec{x}_i \rangle + b) \geq 1 \quad i = 1, \dots, N \end{aligned}$$

- La convexité implique que chaque minimum local est aussi minimum global.

1.2 SVM: le cas séparable

- La solution de ce problème d'optimisation est notée $\vec{w}^*$, b^* et définit la fonction de décision optimale :

$$f(\vec{x}) = \langle \vec{w}^*, \vec{x} \rangle + b^*. \quad (2)$$

- Introduction des multiplicateurs de Lagrange $\alpha_i \geq 0$, un par contrainte.

$$\mathcal{L}(\vec{w}, b, \vec{\alpha}) = \frac{1}{2} \|\vec{w}\|_2^2 - \sum_{i=1}^n \alpha_i \left(y_i (\langle \vec{w}, \vec{x}_i \rangle + b) - 1 \right). \quad (3)$$

- Il est facile de comprendre que $\min_{\vec{w}, b} \mathcal{L}(\vec{w}, b, \vec{\alpha}) \leq \|\vec{w}^*\|^2$ si $\alpha_i \geq 0 \ \forall i$, puisqu'on soustrait des termes non-négatifs.

1.2 SVM: le cas séparable

- On minimise $\mathcal{L}(\vec{w}, b, \vec{\alpha})$ par rapport à $\vec{w}$ et b en mettant les dérivées partielles à 0:

$$\frac{\partial \mathcal{L}(\vec{w}, b, \vec{\alpha})}{\partial \vec{w}} = \vec{w} - \sum_{i=1}^N \alpha_i y_i \vec{x}_i = 0 \quad \Rightarrow \quad \vec{w} = \sum_{i=1}^N \alpha_i y_i \vec{x}_i$$

$$\frac{\partial \mathcal{L}(\vec{w}, b, \vec{\alpha})}{\partial b} = - \sum_{i=1}^N y_i \alpha_i = 0 \quad \Rightarrow \quad \sum_{i=1}^N y_i \alpha_i = 0$$

- On obtient alors : $g(\vec{\alpha}) = \min_{\vec{w}, b} \mathcal{L}(\vec{w}, b, \vec{\alpha})$:

$$g(\vec{\alpha}) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \langle \vec{x}_i \vec{x}_j \rangle$$

1.2 SVM: le cas séparable

- Par construction, nous savons que $g(\vec{\alpha}) \leq \frac{1}{2} \|\vec{w}^*\|^2$ (on rappelle que $\vec{w}^*$ est la solution du problème d'optimisation sous contraintes).
- Si maintenant on maximise par rapport à $\vec{\alpha}$ (sous contraintes $\sum_{i=1}^N y_i \alpha_i = 0$ and $\alpha_i \geq 0$), on obtient la meilleure borne inférieure et - dans ce cas - $g(\vec{\alpha}^*) = \frac{1}{2} \|\vec{w}^*\|^2$.

1.2 SVM: le cas séparable

- Au lieu de résoudre le problème d'optimisation convexe sous contraintes, on résoudra alors le problème dual :

$$\max_{\vec{\alpha}} \quad g(\vec{\alpha}) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \langle \vec{x}_i, \vec{x}_j \rangle$$

$$\text{t.q.} \quad \alpha_i \geq 0 \quad \forall i$$

$$\sum_{i=1}^N \alpha_i y_i = 0$$

1.2 SVM: le cas séparable

- On suppose que $\vec{w}^*$ est une solution du problème primal et $\vec{\alpha}^*$ une solution du problème dual. Alors :

$$\begin{aligned} f(\vec{w}^*) &= g(\vec{\alpha}^*) \\ &= \inf_{\vec{w}, b} \mathcal{L}(\vec{w}, \vec{\alpha}^*, b) \\ &\leq f(\vec{w}^*) - \sum_{i=1}^N \alpha_i^* (y_i (\langle \vec{w}^*, \vec{x}_i \rangle + b^*) - 1) \\ &\leq f(\vec{w}^*) \end{aligned}$$

- Donc: $\forall i \alpha_i^* (y_i (\langle \vec{w}^*, \vec{x}_i \rangle + b^*) - 1) = 0$.
 - $\alpha_i^* = 0$: $\vec{x}_i$ n'est pas sur un hyperplan parallèle.
 - $\alpha_i^* \neq 0$: $\vec{x}_i$ est sur un hyperplan parallèle, la condition est "active" ($\vec{x}_i$ est un vecteur de support).

1.2 SVM: le cas séparable

- On rappelle la solution $\vec{w}^*$ du problème primal:


$$\vec{w}^* = \sum_{i=1}^N \alpha_i y_i \vec{x}_i$$

- $\vec{w}^*$ est donc la somme pondérée des instances $\vec{x}_i$ pour lesquels $\alpha_i \neq 0$ (vecteurs de support).
- La solution pour l'hyperplan séparateur est donc :

$$\begin{aligned} f(\vec{x}) &= \langle \vec{w}, \vec{x} \rangle + b \\ &= \sum_{i=1}^N \alpha_i y_i \langle \vec{x}_i, \vec{x} \rangle + b \\ &= \sum_{i \in SV} \alpha_i y_i \langle \vec{x}_i, \vec{x} \rangle + b \end{aligned}$$

où SV est l'ensemble des vecteurs support.


1.3 SVM pour le cas non-séparable



- Normalement, les données ne sont pas linéairement séparables.
- Dans ce cas, il faut trouver un compromis entre minimiser l'erreur $\sum_{i=1}^N L(\langle \vec{w}, \vec{x}_i \rangle + b, y_i)$ et minimiser la marge $\|\vec{w}\|_2^2$.
- Pour la fonction de perte L , on choisit l'erreur hinge:

$$L_{\text{hinge}}(f(\vec{x}), y) = \max(0, 1 - yf(\vec{x})) = [1 - yf(\vec{x})]_+ \quad (4)$$

1.3 SVM pour le cas non-séparable



- On écrit $\xi_i = [1 - y_i f(\vec{x}_i)]_+$.
- On a donc :
 - $0 < \xi < 1$: classification correcte, mais trop proche de l'hyperplan séparateur
 - $1 < \xi < 2$: classification incorrecte, mais proche de l'hyperplan séparateur
 - $\xi > 2$: classification incorrecte, loin de l'hyperplan séparateur

1.3 SVM pour le cas non-séparable

- Le problème à minimiser devient donc:

$$\begin{aligned} \min_{\vec{w}, \xi} \quad & \frac{1}{2} \|\vec{w}\|_2^2 + C \sum_{i=1}^N \xi_i \\ \text{t.q.} \quad & y_i(\langle \vec{w}; \vec{x}_i \rangle + b) \geq 1 - \xi_i \quad i = 1, \dots, N \\ & \xi_i \geq 0 \quad i = 1, \dots, N \end{aligned}$$

- Nous minimisons la somme de deux termes :
 - La somme d'erreurs de classification
 - Un terme de régularisation $\|\vec{w}\|^2$
- Maximiser la marge revient à faire une L_2 régularisation.
- La solution du problème d'optimisation est similaire au cas précédent.

1.3 SVM pour le cas non-séparable

- Le problème dual s'écrit de façon similaire au cas séparable.



$$\begin{aligned} \max \quad & g(\vec{\alpha}) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \langle \vec{x}_i, \vec{x}_j \rangle \\ \text{t.q.} \quad & \alpha_i \geq 0 \quad \forall i \\ & \alpha_i \leq C \quad \forall i \\ & \sum_{i=1}^N \alpha_i y_i = 0 \end{aligned}$$

- La seule différence par rapport au cas séparable est la contrainte supplémentaire $\alpha_i \leq C$.
- La fonction de décision est toujours donnée par

$$f(\vec{x}) = \sum_{i=1}^N \alpha_i y_i \langle \vec{x}_i, \vec{x} \rangle + b \quad (5)$$



2. Méthode à noyaux

2.1 Motivation



- Limitation de SVM: linéarité.
- Extension possible :
 - 1 transformer les données dans un autre espace (à plus grande dimension)
 - 2 entraîner / appliquer des SVM dans cet espace.

2.1 Motivation



- Dans cet exemple :

$$\begin{aligned}\phi &: \mathbb{R}^2 \rightarrow \mathbb{R}^2 \\ (x_1, x_2) &\mapsto (x_1^2, x_2^2)\end{aligned}$$

- Les données deviennent alors linéairement séparable.

2.2 SVM à noyau

- On suppose que nos données sont définies sur un espace quelconque $\mathcal{X}$ (e.g. $\mathbb{R}^p$).
- Nous allons ensuite redécrire les données dans un espace de Hilbert $\mathcal{H}$ grâce à une application ϕ .

$$\begin{aligned}\phi &: \mathcal{X} \rightarrow \mathcal{H} \\ \vec{x} &\mapsto \phi(\vec{x})\end{aligned}$$

2.2 SVM à noyau

- Le problème dual devient alors :

$$\begin{aligned} \max \quad g(\vec{\alpha}) &= \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \langle \phi(\vec{x}_i), \phi(\vec{x}_j) \rangle \\ \text{t.q.} \quad \alpha_i &\geq 0 \forall i \quad \alpha_i \leq C \forall i \quad \sum_{i=1}^N \alpha_i y_i = 0 \end{aligned}$$

- La fonction de décision est toujours donnée par

$$f(\vec{x}) = \sum_{i=1}^N \alpha_i y_i \langle \phi(\vec{x}_i), \phi(\vec{x}) \rangle + b \tag{6}$$

2.2 SVM à noyau

- Les SVM ne dépendent que des produits scalaires (à l'entraînement et à l'inférence)
- Si on sait comment calculer le produit scalaire dans l'espace $\mathcal{H}$, on peut ne pas faire la transformation ϕ explicitement.
- On parle alors d'astuce de noyau.
- Noyau :

$$\begin{aligned} k &: \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R} \\ \vec{x}, \vec{x}' &\mapsto \langle \phi(\vec{x}), \phi(\vec{x}') \rangle_{\mathcal{H}} \end{aligned}$$

2.2 SVM à noyau

- Avec cela, nous pouvons définir le SVM à noyau

$$\begin{aligned} \max \quad & g(\vec{\alpha}) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j k(\vec{x}_i, \vec{x}_j) \\ \text{t.q.} \quad & \alpha_i \geq 0 \forall i \quad \alpha_i \leq C \forall i \quad \sum_{i=1}^N \alpha_i y_i = 0 \end{aligned}$$

- La fonction de décision est ensuite donnée par :

$$f(\vec{x}) = \sum_{i=1}^N \alpha_i^* y_i k(\vec{x}_i, \vec{x}) + b^* \quad (7)$$

2.3 Les noyaux - Produit scalaire

- $\langle \vec{x}, \vec{x}' \rangle = \sum_{j=1}^p x_j x'_j$
- $\langle \vec{x}, \vec{x}' \rangle = \|\vec{x}\|_2 \|\vec{x}'\|_2 \cos \theta \quad \|\vec{x}\|_2^2 = \langle \vec{x}, \vec{x} \rangle$
- Interprétable comme **mesure de similarité**
- **Forme définie positive bilinéaire :**
 - $\langle \vec{x}, \vec{x}' \rangle = \langle \vec{x}', \vec{x} \rangle$ pour tout $\vec{x}, \vec{x}' \in \mathcal{X}$
 - $\langle \vec{x} + \vec{z}, \vec{x}' \rangle = \langle \vec{x}, \vec{x}' \rangle + \langle \vec{z}, \vec{x}' \rangle$ pour tout $\vec{x}, \vec{x}', \vec{z} \in \mathcal{X}$
 - $\langle a\vec{x}, \vec{x}' \rangle = a\langle \vec{x}, \vec{x}' \rangle$ pour tout $a \in \mathbb{R}$
 - $\langle \vec{x}, \vec{x} \rangle \geq 0$ et $\langle \vec{x}, \vec{x} \rangle = 0$ ssi $\vec{x} = 0$
- Apparaît dans de nombreux algorithmes d'apprentissage.

2.3 Les noyaux - propriétés

- **Généralisation** du produit scalaire : $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$
 - **sémantiquement** une similarité
 - **mathématiquement** une forme définie positive
- Aronszajn: Si k est semi-définie positive¹, il existe un espace de Hilbert $\mathcal{H}$ et une application $\varphi : \mathcal{X} \rightarrow \mathcal{H}$ telle que $k(\vec{x}, \vec{x}') = \langle \varphi(\vec{x}), \varphi(\vec{x}') \rangle_{\mathcal{H}}$ pour tout $\vec{x}, \vec{x}', \vec{z} \in \mathcal{X}$

¹Pour tout $m \in \mathbb{N}^*$, pour tout $\{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_m\} \in \mathcal{X}$, la matrice $K \in \mathbb{R}^{m \times m}$ telle que $K_{il} = k(\vec{x}_i, \vec{x}_l)$ est semi-définie positive

2.3 Les noyaux - Astuce du noyau

$$k(\vec{x}, \vec{x}') = \langle \varphi(\vec{x}), \varphi(\vec{x}') \rangle_{\mathcal{H}}$$

- Si un algorithme ne fait intervenir les éléments de $\mathcal{X}$ que dans des produits scalaires, **remplacer ces produits scalaires** par k est équivalent à appliquer l'algorithme dans $\mathcal{H}$ après avoir appliqué φ
- Utile **si k est plus simple à calculer que φ**

2.3 Les noyaux - Astuce du noyau

$$k(\vec{x}, \vec{x}') = \langle \varphi(\vec{x}), \varphi(\vec{x}') \rangle_{\mathcal{H}}$$



- Si un algorithme ne fait intervenir les éléments de $\mathcal{X}$ que dans des produits scalaires, **remplacer ces produits scalaires** par k est équivalent à appliquer l'algorithme dans $\mathcal{H}$ après avoir appliqué φ
- Utile **si k est plus simple à calculer que φ**
- Exemple : **noyau quadratique** $k : (\vec{x}, \vec{x}') \mapsto (1 + \langle \vec{x}, \vec{x}' \rangle)^2$

Équivaut à $\varphi : (x_1, x_2, \dots, x_p) \mapsto (1, x_1, \dots, x_p, x_1^2, x_2^2, \dots, x_p^2, \sqrt{2}x_1x_2, \dots, \sqrt{2}x_{p-1}x_p)$.

2.3 Les noyaux - Noyau quadratique

$$k : (\vec{x}, \vec{x}') \mapsto (1 + \langle \vec{x}, \vec{x}' \rangle)^2$$

Équivaut à $\varphi : (x_1, x_2, \dots, x_p) \mapsto (1, x_1, \dots, x_p, x_1^2, x_2^2, \dots, x_p^2, \sqrt{2}x_1x_2, \dots, \sqrt{2}x_{p-1}x_p)$.



2.3 Les noyaux - Exemples de noyaux

- **Noyau quadratique** $k : (\vec{x}, \vec{x}') \mapsto (1 + \langle \vec{x}, \vec{x}' \rangle)^2$

φ calcule tous les monômes de degré au plus 2 de $x_1, x_2, \dots, x_p$

2.3 Les noyaux - Exemples de noyaux

- **Noyau quadratique** $k : (\vec{x}, \vec{x}') \mapsto (1 + \langle \vec{x}, \vec{x}' \rangle)^2$

φ calcule tous les monômes de degré au plus 2 de $x_1, x_2, \dots, x_p$

- **Noyau polynomial** $k : (\vec{x}, \vec{x}') \mapsto (1 + \langle \vec{x}, \vec{x}' \rangle)^d$

φ calcule tous les monômes de degré au plus d de $x_1, x_2, \dots, x_p$

2.3 Les noyaux - Exemples de noyaux

- **Noyau quadratique** $k : (\vec{x}, \vec{x}') \mapsto (1 + \langle \vec{x}, \vec{x}' \rangle)^2$

φ calcule tous les monômes de degré au plus 2 de $x_1, x_2, \dots, x_p$

- **Noyau polynomial** $k : (\vec{x}, \vec{x}') \mapsto (1 + \langle \vec{x}, \vec{x}' \rangle)^d$

φ calcule tous les monômes de degré au plus d de $x_1, x_2, \dots, x_p$

- **Noyau RBF gaussien** $k : (\vec{x}, \vec{x}') \mapsto \exp\left(-\frac{\|\vec{x} - \vec{x}'\|_2^2}{\sigma^2}\right)$

φ calcule tous les monômes de $x_1, x_2, \dots, x_p$ et $\mathcal{H}$ est de dimension infinie.

Recap : Méthodes à noyau

- **Idée** : Remplacer dans un algorithme tous les **produits scalaires** par des **noyaux**
- Apprendre des modèles **non-linéaires** efficacement
- Appliquer des modèles linéaires à des **objets** dont la représentation en p dimensions n'est pas évidente (images, protéines, graphes, etc.)

Conclusion: SVM

- Maximiser la marge revient à régulariser le problème de classification.
- Les SVM reposent sur l'optimisation convexe sous contraintes qui est très bien comprise.
- Avec la méthode de noyaux, on a un mécanisme puissant pour passer outre les classifieurs linéaires.
- Les SVM fonctionnent bien si le nombre de descripteurs est plus grand que le nombre d'échantillons dans $\mathcal{D}$.